

代数与分析原理


赵健凯 编著

April 10, 2023



任何建议及错误信息请发送至邮箱

243791757@qq.com



本作品采用知识共享署名-非商业性使用 4.0 国际许可协议进行许可。
访问<http://creativecommons.org/licenses/by-nc/4.0/>查看
该许可协议。

Beauty is the first test : there is no permanent place in the world for ugly mathematics

(美是首要的试金石: 丑陋的数学不可能永存)

G. H. Hardy 哈代

Contents

1 清单定义	1
1.1 Норма вектора. Нормированное пространство	2
1.2 p -норма вектора. Неравенство Гёльдера	3
1.3 Матричная норма. Свойства мультипликативности и согласованности	5
1.4 课件不存在, 引自泛函分析课件 Подчинённая матричная норма. Евклидова норма. Спектральная норма	6
1.5 Изометричная матрица. Классы изометричных матриц для p -нормы и для 2-нормы	7
1.6 Сингулярное разложение матрицы. Сингулярные числа	8
1.7 Унитарно инвариантная норма. Примеры	10
1.8 Ряд Неймана для матриц. Условие его сходимости	11
1.9 Число обусловленности матрицы	12
1.10 Строчное (столбцовое) диагональное преобладание матрицы	13
1.11 Круги Гершгорина	14
1.12 Неравенство Адамара	15
1.13 Хаусдорфово спектральное расстояние между матрицами	16
1.14 Спектральное p -расстояние между матрицами	17
1.15 Аксиомы машинной арифметики	18
1.16 LU -разложение матрицы и условия его существования	19
1.17 Разложение Холецкого и условия его существования	20
1.18 QR -разложение матрицы	21
1.19 Матрица отражения и её основные свойства	22
1.20 Матрица вращения и её основные свойства	24
1.21 Коэффициент перекоса матрицы	25
1.22 Метод поиска характеристического многочлена трёхдиагональной матрицы . .	27
1.23 Метод обратной итерации	28

1.24 Частичная проблема собственных значений. Степенной метод	29
1.25 Итерационные методы решения СЛАУ: явные и неявные, одношаговые и многошаговые	30
1.26 Каноническая форма одношагового итерационного метода. Метод простой итерации	31
1.27 Критерий сходимости стационарного итерационного метода	33
1.28 Скорость сходимости итерационного метода	35
1.29 Обобщённая задача на собственные значения	38
1.30 Многочлен Чебышёва на отрезке $[-1; 1]$, его свойства	39
1.31 Метод минимальных невязок для решения СЛАУ	41
1.32 Метод минимальных поправок для решения СЛАУ	43
1.33 Метод сопряжённых градиентов для решения СЛАУ	45
1.34 Псевдообратная матрица и её использование для решения СЛАУ	48

1 清单定义

1.1 Норма вектора. Нормированное пространство

定义 1.1. (半范数与范数) 设 E 为数域 $\mathbb{K}$ 上向量空间, 称从 E 到 $\mathbb{R}$ 所有满足下列条件的映射 p 为半范数 (*seminorm*)

$$S_1 : (\forall x \in E) : p(x) \geq 0$$

$$S_2 : (\forall x \in E)(\forall \lambda \in \mathbb{K}) : p(\lambda x) = |\lambda|p(x) \text{ (齐次化条件/условие однородности нормы)}$$

$$S_3 : (\forall x, y \in E) : p(x + y) \leq p(x) + p(y) \text{ (三角不等式/неравенство треугольника)}$$

此外, 若 $(\forall x) : [x \neq \mathbf{0} \Rightarrow p(x) \neq 0]$, 则称 p 为范数 (*norm/норма*)

称赋以了一个范数的任一向量空间 E 为赋范空间 (*normed linear space/нормированное пространство*) (或称 (E, p) 为赋范空间)

赋范空间 E 上的与一个范数 p 关联的距离由下式定义:

$$d(x, y) = p(x - y)$$

定义 1.2. (p 范数) 设 $V = \mathbb{C}^n$ 或 $V = \mathbb{R}^n$, 且 $p \geq 1 (p \in \mathbb{R})$ 。对于向量 $x = (x_1, \dots, x_n)^T \in V$, 称

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

为向量 x 的 p 范数

1.2 p -норма вектора. Неравенство Гёльдера

定义 1.3. (p 范数) 设 $V = \mathbb{C}^n$ 或 $V = \mathbb{R}^n$, 且 $p \geq 1 (p \in \mathbb{R})$ 。对于向量 $x = (x_1, \dots, x_n)^T \in V$, 称

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

为向量 x 的 p 范数

若 $p = 1$, 即称范数

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

由 *Manhattan* 距离 (*Manhattan distance*) 定义

若在无穷情况, 则称范数

$$\|x\|_\infty = \max_{i=1, \dots, n} |x_i| = \lim_{p \rightarrow \infty} \|x\|_p$$

由 *Chebyshev* 距离 (*Chebyshev distance/расстояние Чебышёва*) 定义

性质 1.1. (p 范数性质) 函数 $f(p) = \|x\|_p$ 满足下面的性质

$$\forall x \in V, p_1, p_2 > 0 : \|x\|_{p_1} = 1 \Rightarrow \begin{cases} \|x\|_{p_2} \leq 1, p_2 > p_1 \\ \|x\|_{p_2} \geq 1, p_2 < p_1 \end{cases}$$

定理 1.1. (*Hölder* 不等式/*Hölder inequality*) 设 $p, q > 1 : \frac{1}{p} + \frac{1}{q} = 1$, 则对于任意 $a, b \geq 0$ 有

$$ab \leq \frac{a^p}{p} + \frac{b^q}{q}$$

证明. 当 $a = 0$ 或 $b = 0$ 时不等式显然。设 $a, b > 0$, $\lambda = \frac{1}{p}, 1 - \lambda = \frac{1}{q}, x = a^p, y = b^q$, 则有函数 $f(x) = \ln(x)$, 由 $f''(x) < 0$ 得

$$(\forall \lambda \in [0; 1]) : \lambda \ln(x) + (1 - \lambda) \ln(y) \leq \ln(\lambda x + (1 - \lambda)y)$$

即函数在 $x > 0$ 上凸, 即有

$$\lambda \ln(x) + (1 - \lambda) \ln(y) = \ln(ab) \leq \ln(\lambda x + (1 - \lambda)y) = \ln\left(\frac{a^p}{p} + \frac{b^q}{q}\right)$$

不等式即证 □

定理 1.2. (*Hilbert* 不等式/*Hilbert inequality/неравенство Гёльдера*) 对于任意 $p, q > 1 :$

$\frac{1}{p} + \frac{1}{q} = 1$, 任意 $x, y \in V = \mathbb{C}^n (\mathbb{R}^n)$, 则有 Hilbert 不等式

$$\left| \sum_{i=1}^n x_i y_i \right| \leq \|x\|_p \cdot \|y\|_q$$

证明. 当 $x = 0$ 或 $y = 0$ 时不等式显然。下设 $x, y \neq 0$, $\tilde{x} = \frac{x}{\|x\|_p}, \tilde{y} = \frac{y}{\|y\|_q}$, 则 $\|\tilde{x}\|_p = \|\tilde{y}\|_q = 1$ 。利用 Holder 不等式 (1.1) 在 $a = \tilde{x}_i, b = \tilde{y}_i, i = 1, \dots, n$ 时:

$$|\tilde{x}_i| \cdot |\tilde{y}_i| \leq \frac{|\tilde{x}_i|^p}{p} + \frac{|\tilde{y}_i|^q}{q}$$

对 $i = 1, \dots, n$ 累加则得

$$\frac{1}{\|x\|_p \|y\|_q} \left| \sum_{i=1}^n x_i y_i \right| \leq \sum_{i=1}^n |\tilde{x}_i| \cdot |\tilde{y}_i| \leq \sum_{i=1}^n \left(\frac{|\tilde{x}_i|^p}{p} + \frac{|\tilde{y}_i|^q}{q} \right) = \frac{\|\tilde{x}\|_p^p}{p} + \frac{\|\tilde{y}\|_q^q}{q} = 1$$

不等式即证 □

定理 1.3. (*Minkowski 不等式/Minkowski inequality/неравенство Минковского*) 对于任意 $p > 1$, 任意 $x, y \in V = \mathbb{C}^n (\mathbb{R}^n)$, 有不等式

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p$$

证明. 使用两次 Hilbert 不等式 (1.2), 其中令 $(p-1)q = p$, 有

$$\begin{aligned} \sum_{i=1}^n |x_i| \cdot |x_i + y_i|^{p-1} &\leq \|x\|_p \cdot \left(\sum_{i=1}^n (|x_i + y_i|^{p-1})^q \right)^{\frac{1}{q}} = \|x\|_p \cdot (\|x + y\|_p)^{\frac{p}{q}} \\ \sum_{i=1}^n |y_i| \cdot |x_i + y_i|^{p-1} &\leq \|y\|_p \cdot \left(\sum_{i=1}^n (|x_i + y_i|^{p-1})^q \right)^{\frac{1}{q}} = \|y\|_p \cdot (\|x + y\|_p)^{\frac{p}{q}} \end{aligned}$$

则有

$$\|x + y\|_p^p = \sum_{i=1}^n |x_i + y_i|^p \leq \sum_{i=1}^n (|x_i| + |y_i|) |x_i + y_i|^{p-1} \leq (\|x + y\|_p)^{\frac{p}{q}} (\|x\|_p + \|y\|_p)$$

将不等式除以 $(\|x + y\|_p)^{\frac{p}{q}}$ 即得 □

1.3 矩阵范数. 性质 乘法性 (свойства мультипликативности)

定义 1.4. (矩阵范数) 设矩阵 $A \in \mathbb{C}^{m \times n}$, 若范数满足

S_1 : (非负性) $(\forall A \in \mathbb{C}^{m \times n}) : \|A\| \geq 0$ 且 $(\forall A \in \mathbb{C}^{m \times n}) : [A \neq O \Rightarrow \|A\| \neq 0]$

S_2 : (齐次性) $(\forall A \in \mathbb{C}^{m \times n})(\forall \lambda \in \mathbb{C}) : \|\lambda A\| = |\lambda| \cdot \|A\|$

S_3 : (三角不等式) $(\forall A, B \in \mathbb{C}^{m \times n}) : \|A + B\| \leq \|A\| + \|B\|$

S_4 : (相容性 (согласованности)/乘法性质 (свойство мультипликативности))

$$(\forall A, B \in \mathbb{C}^{m \times n}) : \|AB\| \leq \|A\| \cdot \|B\|$$

则称范数为矩阵范数

例题 1.1. (Frobenius 范数为矩阵范数) Frobenius 范数, 即

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^m |a_{ij}|^2 \right)^{\frac{1}{2}}, A \in \mathbb{C}^{m \times n}$$

为矩阵范数

证明. 非负性与齐次性易证, 下证三角不等式与相容性。

三角不等式: 设 $A = (a_{ij})_{m \times n}, B = (b_{ij})_{m \times n}$, 即由 Minkowski 不等式 (1.3) 有

$$\begin{aligned} \|A + B\|_F &= \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij} + b_{ij}|^2 \right)^{\frac{1}{2}} \\ &\leq \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} + \left(\sum_{i=1}^m \sum_{j=1}^n |b_{ij}|^2 \right)^{\frac{1}{2}} = \|A\|_F + \|B\|_F \end{aligned}$$

相容性: 设 $A = (a_{ij})_{m \times l}, B = (b_{ij})_{l \times n}$, 则有

$$\|AB\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n \left| \sum_{k=1}^l a_{ik} b_{kj} \right|^2 \leq \sum_{i=1}^m \sum_{j=1}^n \left(\sum_{k=1}^l |a_{ik}| |b_{kj}| \right)^2$$

则由 Hölder 不等式 (1.1) 即得

$$\begin{aligned} \|AB\|_F^2 &\leq \sum_{i=1}^m \sum_{j=1}^n \left[\left(\sum_{k=1}^l |a_{ik}|^2 \right) \left(\sum_{k=1}^l |b_{kj}|^2 \right) \right] \\ &= \left(\sum_{i=1}^m \sum_{k=1}^l |a_{ik}|^2 \right) \left(\sum_{j=1}^n \sum_{k=1}^l |b_{kj}|^2 \right) = \|A\|_F^2 \|B\|_F^2 \end{aligned}$$

则有 $\|AB\|_F \leq \|A\|_F \|B\|_F$

□

1.4 课件不存在, 引自泛函分析课件 Подчинённая матричная норма. Евклидова норма. Спектральная норма

定理 1.4. (等价范数定理/теорема об эквивалентных нормах) 设在 Banach 空间 E 上给定两个范数 $\|x\|_1$ 和 $\|x\|_2$, 若一个范数属于另一个范数, 则这些范数等价

证明. 设 X_1 在 E 上有范数 $\|x\|_1$, 而 X_2 在 E 上有范数 $\|x\|_2$, 设范数 $\|\cdot\|_1$ 属于范数 $\|\cdot\|_2$, 则有

$$(\exists c > 0)(\forall x \in E) : \|x\|_1 \leq c\|x\|_2$$

定义算子 $\mathcal{A}$, 将 X_2 映上 X_1 , 即 $\mathcal{A}(x) = x, D(\mathcal{A}) = X_2, \mathcal{A}$ 为线性的, 并将 X_2 映到 $R(\mathcal{A}) = X_1$ 。由范数属于条件, $\|\mathcal{A}\| \leq c$, 算子 $\mathcal{A}$ 有界且为闭算子。则由 Banach 空间上双闭算子有界性(??) 有 $\mathcal{A}^{-1} \in \mathcal{L}(X_1, X_2)$, 则

$$\|x\|_2 \leq \|\mathcal{A}^{-1}\| \cdot \|x\|_1 \Rightarrow c_1\|x\|_2 \leq \|x\|_1 \leq c\|x\|_2$$

其中 $c_1 = (\|\mathcal{A}^{-1}\|)^{-1}$, 定理即证 □

定理 1.5. (有限维线性赋范空间等价性) 任意有限维线性赋范空间 E 的范数等价, 且对于任意范数 $\|\cdot\|_1, \|\cdot\|_2$ 存在 $C_1, C_2 > 0$, 满足

$$(\forall x \in E) : C_1\|x\|_1 \leq \|x\|_2 \leq C_2\|x\|_1$$

例题 1.2. 矩阵谱范数 (спектральная норма): $\|A\|_2$ 为 $\sqrt{|\lambda|}$ 最大值, 其中 λ 为 AA^* 与 A^*A 特征值

1.5 Изометричная матрица. Классы изометричных матриц для p -нормы и для 2-нормы

定义 1.5. (保范) 设矩阵 $Q \in \mathbb{C}^{n \times n}$, 若 $(\forall x \in \mathbb{C}^n) : \|Qx\| = \|x\|$, 则称矩阵在 $\mathbb{C}^n$ 上保范 (сохраняющая норма) 或在空间 $\mathbb{C}^n$ 上相对于范数等距 (изометрично относительно нормы)

例题 1.3. (置换矩阵保范性) 设 Q 为置换矩阵 (матрица перестановки), 即行或列置换的单位矩阵 (единичная матрица с перестановкой строк или столбцов), 则 Q 保范

证明. 设 $\|\cdot\|_p$ 为矩阵 p 范数, $x = e_i$ 为单位矩阵第 i 列。则矩阵 Q 每一列 p 范数等于 1, 此外由 Hilbert 不等式 (1.2) 有

$$\|Q^T y\|_q = \max_{x \neq \theta} \frac{|y^T Qx|}{\|x\|_p} = \max_{x \neq \theta} \frac{|y^T Qx|}{\|Qx\|_p} = \max_{z \neq \theta} \frac{|y^T z|}{\|z\|_p} = \|y\|_q$$

则可推出矩阵 Q 任意行的 q 范数等于 1

设 $p < 2, q > 2, \frac{1}{p} + \frac{1}{q} = 1$, 对于矩阵 Q 的任意列 q_i 与任意行 $\tilde{q}_j^T$ 有

$$\|q_i\|_2 \leq \|q_i\|_p = 1, \|\tilde{q}_j^T\|_2 \geq \|\tilde{q}_j^T\|_q = 1, \sum_{i=1}^n \|q_i\|_2^2 = \sum_{j=1}^n \|\tilde{q}_j\|_2^2$$

仅当若 $(\forall i, j) : \|q_i\|_2 = \|\tilde{q}_j\|_2 = 1 \Rightarrow (\forall i) : \|q_i\|_p = \|q_i\|_2 = 1$, 则在 q_i 元素等于 1, 沿范数等于 1 时, 其余元素为零时成立

上述讨论对于行同理, $p > 2$ 同理。因此当 $p \neq 2$ 时 $Q = P \text{diag}(d_1, \dots, d_n)$, 其中 P 为置换矩阵, $(\forall i) : |d_i| = 1$ □

1.6 Сингулярное разложение матрицы. Сингулярные числа

定理 1.6. (奇异值分解定理/SVD 定理/Autonee-Eckart-Young 定理) 设 $A \in \mathbb{C}^{n \times m}, r = \text{rank}(A)$, 则存在奇异值 (сингулярные числа) $\sigma_1 \geq \dots \geq \sigma_r > 0$ 与酉矩阵 $U \in \mathbb{C}^{m \times m}, V \in \mathbb{C}^{n \times n}$ 满足

$$A = V \Sigma U^*, \Sigma = \begin{pmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \\ 0 & \dots & 0 \end{pmatrix} \in \mathbb{C}^{n \times m}$$

证明. 矩阵 A^*A 为正规 Hermite 矩阵, 则存在酉矩阵 $U = [u_1, \dots, u_m] \in \mathbb{C}^{m \times m}$ 满足

$$U^* A^* A U = \text{diag}(\sigma_1^2, \dots, \sigma_m^2), \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$$

设 $\sigma_r > 0, (\forall i > r) : \sigma_i = 0, U_r = [u_1, \dots, u_r], \Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$, 则有

$$U_r^* A^* A U_r = \Sigma_r^2 \Rightarrow (\Sigma_r^{-1} U_r^* A^*) (A U_r \Sigma_r^{-1}) = I$$

下记 $V_r = A U_r \Sigma_r^{-1} = [v_1, \dots, v_r]$, 则 $V_r^* V_r = I$ 推出 V_r 为酉矩阵。这时 $(\forall i \in \overline{1, r}) : A u_i = \sigma_i v_i$, 而 $(\forall i \geq r+1) : u_i^* A^* A u_i = \|A u_i\|_2^2 = 0$ 得 $A u_i = 0$ 。将 V_r 扩展为酉矩阵 $V \in \mathbb{C}^{n \times n}$, 则有

$$A U = V \begin{pmatrix} \Sigma_r & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow V^* A U = \begin{pmatrix} \Sigma_r & 0 \\ 0 & 0 \end{pmatrix}$$

则由乘上非退化矩阵秩不变有 $\text{rank}(A) = r$ □

定义 1.6. (左奇异向量与右奇异向量) 定义向量 v_i 与 u_i 满足

1) 奇异值 σ_i 单值定义

2) 若 $\sigma_1 > \dots > \sigma_r > 0$, 则向量 $u_1, \dots, u_r$ 与 $v_1, \dots, v_r$ 满足

$$A u_i = \begin{cases} \sigma_i v_i, & i = \overline{1, r} \\ 0, & i = \overline{r+1, m} \end{cases}$$

$$A^* v_i = \begin{cases} \sigma_i u_i, & i = \overline{1, r} \\ 0, & i = \overline{r+1, n} \end{cases}$$

则称向量 v_i 为左奇异向量, 称 u_i 为右奇异向量

性质 1.2. (左奇异向量与右奇异向量性质) 左奇异向量与右奇异向量满足下列命题:

1) $A = \sum_{i=1}^r \sigma_i v_i u_i^*$

$$2) \ker(A) = \mathcal{L}(u_{r+1}, \dots, u_m)$$

$$3) \operatorname{im}(A) = \mathcal{L}(v_1, \dots, v_r)$$

$$4) \ker(A^*) = \mathcal{L}(v_{r+1}, \dots, v_n)$$

$$5) \operatorname{im}(A^*) = \mathcal{L}(u_1, \dots, u_r)$$

1.7 酉不变范数. 例子

定义 1.7. (酉不变范数) 设 $\forall A \in \mathbb{C}^{n \times m}, \forall U \in \mathbb{C}^{k \times n}, V \in \mathbb{C}^{m \times l}$, 且 $\|\cdot\|$ 为矩阵范数, 若

$$U, V \in \mathcal{U} \Rightarrow \|A\| = \|UAV\|$$

则称矩阵范数 $\|\cdot\|$ 为酉不变范数 (унитарно инвариантная норма)

定理 1.7. (谱范数酉不变性) 谱范数酉不变

证明. 由 Weierstrass 定理连续函数 $y = \|Ax\|_2$ 必在某个点 z 达上下界 $\{x : \|x\|_2 = 1\}$, 则有 $\|z\|_2 = 1, Az = \sigma y, \|y\|_2 = 1$ 。构造酉矩阵 $U = [z, U_1]$ 与 $V = [y, V_1]$, 则有

$$V^*AU = \begin{bmatrix} y^* \\ V_1^* \end{bmatrix} [\sigma y, AU_1] = \begin{pmatrix} \sigma & b^* \\ 0 & B \end{pmatrix},$$

$$\left\| V^*AU \begin{bmatrix} \sigma \\ b \end{bmatrix} \right\|_2^2 \geq (\sigma^2 + b^*b)^2, \quad \|(\sigma, b^*)\|_2^2 = \sigma^2 + b^*b \Rightarrow \|V^*AU\|_2^2 \geq \sigma^2 + b^*b$$

则有 $\|A\|_2 = \|V^*AU\|_2 = \sigma$

□

1.8 Ряд Неймана для матриц. Условие его сходимости

定义 1.8. (Neumann 级数) 称矩阵级数 $\sum_{k=0}^{\infty} F^k$ 为 **Neumann 级数 (ряд Неймана)**

定理 1.8. (Neumann 级数收敛充分条件) 若 $\|F\| < 1$, , 则有其 Neumann 级数收敛

证明. 由条件及 $\|F^k\| \leq \|F\|^k$, 则有数值级数 $\sum_{k=0}^{\infty} \|F^k\|$ 收敛, 则由矩阵级数收敛充分条件 (??), 即得其 Neumann 级数收敛 $\square$

引理 1.1. (Neumann 级数收敛充要条件) 矩阵为 $F \in \mathbb{C}^{n \times n}$ 的 Neumann 级数收敛的充要条件为矩阵 F 收敛

证明. 充分性: 由 Schur 分解定理 (??) 存在酉矩阵 Q (由酉性有 $Q^{-1} = Q^*$) 满足 $T = (t_{ij}) = Q^{-1}FQ$ 为上三角矩阵, 则有

$$T^k = Q^{-1}F^kQ \Rightarrow \text{级数 } \sum_{k=0}^{\infty} F^k \text{ 收敛} \Leftrightarrow \text{级数 } \sum_{k=0}^{\infty} T^k \text{ 收敛}$$

设 $D_\varepsilon = \text{diag}(1, \varepsilon, \dots, \varepsilon^{n-1})$, 则有 $(\forall i \leq j) : \{D_\varepsilon^{-1}TD_\varepsilon\}_{ij} = \varepsilon^{j-i}t_{ij}$

矩阵 $D_\varepsilon^{-1}TD_\varepsilon$ 的对角线元绝对值小于 1, 则有当 $\varepsilon > 0$ 充分小时有 $\|D_\varepsilon^{-1}TD_\varepsilon\|_2 < 1$, 则由 Neumann 级数收敛充分条件 (1.8) 有矩阵为 $D_\varepsilon^{-1}TD_\varepsilon$ 的 Neumann 级数收敛, 则有

$$(D_\varepsilon^{-1}TD_\varepsilon)^k = D_\varepsilon^{-1}T^kD_\varepsilon \Rightarrow \text{级数 } \sum_{k=0}^{\infty} T^k \text{ 收敛} \Leftrightarrow \text{级数 } \sum_{k=0}^{\infty} (D_\varepsilon^{-1}TD_\varepsilon)^k \text{ 收敛}$$

必要性: 反证, 则有

$$(\exists \lambda)(|\lambda| \geq 1)(\exists \tilde{x} \neq \theta)(F\tilde{x} = \lambda\tilde{x}) : \sum_{k=0}^N F^k \tilde{x} = (1 + \lambda + \dots + \lambda^N) \tilde{x}$$

但 $\nexists \lim_{N \rightarrow +\infty} (1 + \lambda + \dots + \lambda^N)$ 即有 Neumann 级数发散, 矛盾 $\square$

1.9 Число обусловленности матрицы

定义 1.9. (条件数) 设 A 为非退化矩阵, 观察方程组 $Ax = f, f \neq \theta$ 与扰动方程组 $(A + \Delta A)\tilde{x} = f + \Delta f$, 若 $\|A^{-1}\Delta A\| < 1$, 则有

$$\begin{aligned}\tilde{x} - x &= (A + \Delta A)^{-1}(f + \Delta f) - A^{-1}f = ((A + \Delta A)^{-1} - A^{-1})f + (A + \Delta A)^{-1}\Delta f \\ &= \left((I + A^{-1}\Delta A)^{-1} - I\right)(A^{-1}f) + (I + A^{-1}\Delta A)^{-1}(A^{-1}\Delta f) \\ &= \left(\sum_{k=1}^{\infty} (-A^{-1}\Delta A)^k\right)(A^{-1}f) + \left(\sum_{k=0}^{\infty} (-A^{-1}\Delta A)^k\right)(A^{-1}\Delta f)\end{aligned}$$

用 $\|\tilde{x} - x\|$ 除以 $\|x\| = \|A^{-1}f\|$ 并估计解的相对误差 (*относительная погрешность*), 利用不等式 $\|f\| \leq \|A\| \cdot \|x\|$ 则有

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \|A^{-1}\Delta A\| \sum_{k=0}^{\infty} \|A^{-1}\Delta A\|^k + \frac{\|A^{-1}\| \|\Delta f\| \|A\|}{\|f\|} \sum_{k=0}^{\infty} \|A^{-1}\Delta A\|^k$$

由条件计算级数 $\sum_{k=0}^{\infty} \|A^{-1}\Delta A\|^k = \frac{1}{1 - \|A^{-1}\Delta A\|}$ 后整理得

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|A\|}{1 - \|A^{-1}\Delta A\|} \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta f\|}{\|f\|} \right)$$

于是称 $\text{cond}(A) = \|A^{-1}\| \cdot \|A\|$ 为矩阵 A 的条件数 (*число обусловленности*)

注意 1.1. (条件数) 条件数表征解 x 对矩阵和右侧部分的微小扰动的敏感性 (*чувствительность*), 对于非退化矩阵一般有 $\text{cond } A = \infty$

例题 1.4. (谱范数条件数) 设谱范数 $\|A\|_2 = \sigma_1(A) = \sigma_{\max}(A)$, 则显然有

$$\|A^{-1}\|_2 = \sigma_{\max}(A^{-1}) = \frac{1}{\sigma_{\min}(A)}$$

则有

$$\text{cond}_2 A = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$$

注 1: 几何解释: $\text{cond}_2(A)$ 表明变换 A 沿其主方向不均匀地拉伸空间

注 2: 在范数 $\|\cdot\|_1$ 与 $\|\cdot\|_{\infty}$ 中计算矩阵条件数时, 可考虑利用

$$\|A\|_{\infty} = \|A^T\|_1 \Rightarrow \text{cond}_{\infty} A = \text{cond}_1 A^T$$

1.10 Строчное (столбцовое) диагональное преобладание матрицы

定义 1.10. (对角线优越/диагональное преобладание) 设矩阵 $A = \{a_{ij}\} \in \mathbb{C}^{n \times n}$ 若

$$(\forall i \in \overline{1; n}) : |a_{ii}| > r_i = \sum_{j=1, j \neq i}^n |a_{ij}|$$

则称矩阵 A 行对角线优越 (строчное диагональное преобладание)

对称地, 若

$$(\forall j \in \overline{1; n}) : |a_{jj}| > c_j = \sum_{i=1, i \neq j}^n |a_{ij}|$$

则称矩阵 A 列对角线优越 (столбцовое диагональное преобладание)

定理 1.9. (矩阵对角线优越必要条件) 具有行或列对角线优越的矩阵非退化

证明. 设 $\text{diag}(A) = \text{diag}(a_{11}, \dots, a_{nn})$, $\text{off}(A) = A - \text{diag}(A)$ 。不妨设 A 有严格行对角线优越, 则由定义有所有对角线元不等于 0, 则 A 有严格行对角线优越 $\Leftrightarrow \|(\text{diag}(A))^{-1} \text{off}(A)\|_{\infty} < 1$, 这意味着 $A = \text{diag}(A)(I + (\text{diag}(A))^{-1} \text{off}(A))$ 非退化, 由引理 (??) 即得。同理可证列对角线优越, 仅需将 A 变为 A^T 即得 $\square$

1.11 Круги Гершгорина

定理 1.10. (Gerschorin 圆性质) 设矩阵 $A \in \mathbb{C}^{n \times n}$, 考虑圆

$$R_i = \{z \in \mathbb{C} : |a_{ii} - z| \leq r_i\}, \quad C_i = \{z \in \mathbb{C} : |a_{ii} - z| \leq c_i\}$$

其中

$$r_i = \sum_{j=1, j \neq i}^n |a_{ij}|, \quad c_j = \sum_{i=1, i \neq j}^n |a_{ij}|$$

则有

$$(\forall \lambda \in \lambda(A)) : \left(\lambda \in \bigcup_{i=1}^n R_i \right) \wedge \left(\lambda \in \bigcup_{i=1}^n C_i \right)$$

证明. 若 $\lambda \notin \cup_i R_i$, 则矩阵 $A - \lambda I$ 具有行对角优越, 则由矩阵对角线优越必要条件 (1.9) 有, 矩阵 $A - \lambda I$ 为非退化矩阵, 进而 λ 不为特征值。对称地, 当矩阵 C_i 具有列对角线优越, 同理即证 $\square$

注: 称该定理中圆 R_i, C_i 为 **Gerschorin 圆**

定理 1.11. (Gerschorin 圆盘定理) 若 m 个 Gerschorin 圆构成了与其他圆孤立的区域 G , 则有 m 个矩阵 A 的特征值位于区域 G 中

证明. 设 $A(t) = \text{diag}(A) + t \cdot \text{off}(A) = A - \text{diag}(A), t \in [0; 1]$ 。用 $G(t)$ 表示与 G 中的圆具有相同中心的 Gerschorin 圆盘的并集, 用 $G'(t)$ 表示其余圆盘的并集, 则 $A(1) \equiv A$ 且

$$G(t) \subset G(1) = G, \quad G'(t) \subset G'(1) = G'$$

再由条件 $G \cap G' = \emptyset$ 有 $G(t) \cap G'(t) = \emptyset, t \in [0; 1]$

由定理 (??) 有, 存在连续的 $\lambda_1(t), \dots, \lambda_m(t)$ 满足

$$\{\lambda_1(0), \dots, \lambda_m(0)\} = G(0), \quad \lambda_1(t), \dots, \lambda_m(t) \in \lambda(A(t)), t \in [0; \varepsilon)$$

再令 $t_i = \sup \{t \geq 0 | \lambda_i(t) \in G(t)\}$

若 $t_i < 1$, 则 $(\forall t > t_i) : \lambda_i(t) \in G'(t)$ 。但由连续性有: $\lambda_i(t_i) \in G(t_i) \cap G'(t_i) \neq \emptyset$, 则导出矛盾, 即有 $(\forall i \in \overline{1; m}) : t_i \geq 1$, 则 $\lambda_1(1), \dots, \lambda_m(1) \in G$ $\square$

推论 1.12. 若 Gerschorin 圆盘两两互不相交, 则其中每一个都恰好仅包含一个特征值

1.12 Неравенство Адамара

定理 1.13. (Hadamard 不等式) 设矩阵 $A = \begin{bmatrix} a_1 & \dots & a_n \end{bmatrix} \in \mathbb{C}^{n \times n}$, $\det A \neq 0$, 则有

$$|\det(A)| \leq \|a_1\|_2 \cdot \dots \cdot \|a_n\|_2$$

证明. 对向量 $a_1, \dots, a_n$ 进行 Gram-Schmidt 正交化, 则得标准正交向量组 $b_1, \dots, b_n$, 则 $B = \begin{bmatrix} b_1 & \dots & b_n \end{bmatrix}$ 为一个标准正交矩阵。由 Gram-Schmidt 正交化得存在上三角矩阵 $C = (c_{ij})$, 满足 $A = BC$, 这时

$$\begin{aligned} (1 \leq i \leq j) : c_{ij} &= \langle a_j, b_i \rangle; \quad (j \leq i \leq n) : c_{ij} = 0 \\ (\forall i \in \overline{1; n} : a_i &= \sum_{j=1}^i \langle a_i, b_j \rangle b_j, \quad \|a_i\|_2^2 = \sum_{j=1}^i |\langle a_i, b_j \rangle|^2 \end{aligned}$$

则有

$$\begin{aligned} |\det A|^2 &= \det(A^* A) = \det(C^* B^* B C) = \det C^* C = |\det C|^2 = \prod_{i=1}^n |\langle a_i, b_i \rangle|^2 \\ &\leq \prod_{i=1}^n \sum_{j=1}^i |\langle a_i, b_j \rangle|^2 = \prod_{i=1}^n \|a_i\|_2^2 \end{aligned}$$

不等式即证 □

注: Hadamard 不等式取等充要条件为

$$(\forall i) : |\langle a_i, b_i \rangle|^2 = \sum_{j=1}^i |\langle a_i, b_j \rangle|^2 \Leftrightarrow (\forall i) : a_i = \langle a_i, b_i \rangle b_i$$

1.13 Хаусдорфово спектральное расстояние между матрицами

定义 1.11. (*Hausdorff* 谱距离) 设 $A, B \in \mathbb{C}^{n \times n}$, 且 $\{\lambda_i\}, \{\mu_j\}$ 分别为 A, B 的谱, 则称

$$\text{hd}(A, B) = \max \left\{ \max_i \min_j |\lambda_i - \mu_j|, \max_j \min_i |\lambda_i - \mu_j| \right\}$$

为矩阵 A 和 B 之间的 *Hausdorff* 谱距离

定理 1.14. (*Hausdorff* 谱距离估计) 设 $A, B \in \mathbb{C}^{n \times n}$, 则满足

$$\text{hd}(A, B) \leq (\|A\|_2 + \|B\|_2)^{1-\frac{1}{n}} \cdot \|A - B\|_2^{\frac{1}{n}}$$

证明. 设向量 $x_1, \dots, x_n$ 构成酉矩阵的列, 且有 $Bx_1 = \mu x_1$ 。若 $\lambda_1, \dots, \lambda_n$ 为矩阵 A 的特征值, 则有

$$\begin{aligned} \left(\min_i |\lambda_i - \mu| \right)^n &\leq \prod_{i=1}^n |\lambda_i - \mu| = |\det((A - \mu I)X)| \leq \prod_{i=1}^n \|(A - \mu I)x_i\|_2 \\ &\leq \|(A - B)x_1\|_2 \cdot \prod_{i=2}^n \|(A - \mu I)x_i\|_2 \leq \|A - B\|_2 \cdot (\|A\|_2 + \|B\|_2)^{n-1} \end{aligned}$$

定理即证 □

1.14 Спектральное p -расстояние между матрицами

定义 1.12. (谱 p 距离) 设 $A, B \in \mathbb{C}^{n \times n}$, 且 $\{\lambda_i\}, \{\mu_j\}$ 分别为 A, B 的谱, $\lambda(A) = [\lambda_1, \dots, \lambda_n]^T, \lambda(B) = [\mu_1, \dots, \mu_n]^T$, 则称

$$d_p(A, B) = \min_P \{\|\lambda(A) - P\lambda(B)\|_p\}$$

为矩阵 A 和 B 之间的谱 p 距离, 其中 P 为置换矩阵

定理 1.15. (谱 ∞ 距离估计) 设 $A, B \in \mathbb{C}^{n \times n}$, 则满足

$$d_\infty(A, B) \leq (2n - 1) \text{hd}(A, B)$$

证明. 设 λ_i 为矩阵 A 的特征值, 考虑圆

$$D_i = \{z : |z - \lambda_i| \leq \text{hd}(A, B)\}, \quad D_i(\tau) = \{z : |z - \lambda_i| \leq \varepsilon(\tau)\}$$

其中

$$\varepsilon(\tau) = \left(\|A\|_2 + \max_{t \in [0;1]} \|A + t(B - A)\|_2 \right)^{1 - \frac{1}{n}} \cdot \|\tau(B - A)\|_2^{\frac{1}{n}}, \quad \tau \in [0; 1]$$

根据 Hausdorff 谱距离估计 (1.14), 矩阵 $A + \tau(B - A)$ 的所有特征值都包含在圆 $D_i(\tau), i = 1, \dots, n$ 的并集中

类似 Gerschgorin 圆的讨论, 若 m 个圆 $D_i(\tau)$ 相对于其余的圆孤立, 则它们的并集正好包含矩阵 $A + \tau(B - A)$ 的 m 个特征值。若 m 个圆 $D_i(1)$ 相对于其余的圆孤立, 则它们对于圆 D_i 的并集正好包含 m 个特征值 μ_i ($\text{hd}(A, B) \leq \varepsilon(1)$)

假设矩阵 B 的圆和特征值 μ_i 的序号满足:

$$(\forall i \in \overline{1; m}) : \mu_i \in \bigcup_{1 \leq k \leq m} D_k$$

则 $(\forall i, j \in \overline{1; m}) : |\mu_i - \lambda_j| \leq (1 + 2(m - 1)) \text{hd}(A, B)$ 。在最坏的情况下 $m = n$ □

1.15 Аксиомы машинной арифметики

定义 1.13. (机器算术公理) 当将数字输入计算机并使用机器数执行操作时, 通常会发生数字的舍入操作。舍入为一个由实数集到机器数集的映射。若 x 为一个实数, $\text{fl}(x)$ 为舍入映射的值, 则有机器算术公理 (*аксиома машинной арифметики*): $\text{fl}(x) = x(1 + \varepsilon)$, 其中若 $\text{fl}(x) \neq 0$, 则满足 $|\varepsilon| \leq \eta$ 。称 ε 为相对舍入误差 (*относительная погрешность округления*)

机器数 a 和 b 的二元运算 $(*)$ 的结果用 $\text{fl}(a*b)$ 表示, 则有机器算术公理 (*аксиома машинной арифметики*): 若 $\text{f}(a*b) \neq 0$, 则 $\text{f}(a*b) = (a*b)(1 + \varepsilon), |\varepsilon| \leq \eta$

注意 1.2. (机器算术公理) 若在舍入实数时, 选择最接近其的机器数, 则 $\eta = \frac{1}{2}p^{1-t}$, 设 a 为数的真实值, 而 $\tilde{a} = \text{fl}(a)$ 为其对应机器数, 则有

$$a = \pm \left(\frac{d_1}{p} + \frac{d_2}{p^2} + \dots + \frac{d_t}{p^t} + \frac{d_{t+1}}{p^{t+1}} + \dots \right) \cdot p^\alpha$$

若考虑标准化数组, 则尾数的模长 $\geq \frac{1}{p}$, 即 $|a| \geq p^{\alpha-1}$ 。对于尾数舍入的绝对误差, 搜索最近元素的方法为找到满足的如下估算的元素:

$$|a - \tilde{a}| \leq \frac{1}{2}p^\alpha \frac{1}{p^{t+1}} \left(1 + \frac{1}{p} + \frac{1}{p^2} + \dots \right) \leq \frac{1}{2}p^{\alpha-t} \Rightarrow \frac{|a - \tilde{a}|}{|a|} \leq \frac{1}{2}p^{1-t}$$

同理, 通过删除数位 $\eta = p^{1-t}$ 舍入

1.16 LU-разложение матрицы и условия его существования

定义 1.14. (LU 分解) 设矩阵分解式 $A = LU$, 其中矩阵 L 为对角线元素均为 1 的下三角矩阵, 矩阵 U 为非退化上三角矩阵, 则称该分解为矩阵 A 的 **LU 分解** (**LU-разложение**)

定理 1.16. (LU 分解存在性充要条件) 矩阵 A 的 LU 分解存在的充要条件为矩阵 A 为严格正则矩阵

证明. 必要性: 设 $A = LU$, 则矩阵 A 及其任意顺序主子矩阵 B 都可表示为两个非退化三角矩阵乘积的形式, 则矩阵 A, B 均为非退化矩阵, 则 A 为严格正则矩阵

充分性: 对矩阵 A 维数归纳, 假设

$$A = \begin{bmatrix} a & c^T \\ b & D \end{bmatrix}, \quad a \neq 0, \quad z = \frac{1}{a}b, \quad A_1 = D - \frac{1}{a}bc^T$$

则可以改写为

$$\begin{bmatrix} 1 & 0 \\ -z & I \end{bmatrix} \begin{bmatrix} a & c^T \\ b & D \end{bmatrix} = \begin{bmatrix} a & c^T \\ 0 & A_1 \end{bmatrix}$$

则矩阵 A_1 为严格正则矩阵。则根据归纳假设, A_1 有 LU 分解 $A_1 = L_1 U_1$ 。再令

$$L = \begin{bmatrix} 1 & 0 \\ z & L_1 \end{bmatrix}, \quad U = \begin{bmatrix} a & c^T \\ 0 & U_1 \end{bmatrix}$$

即得

$$LU = \begin{bmatrix} a & c^T \\ b & L_1 U_1 + \frac{1}{a}bc^T \end{bmatrix} = \begin{bmatrix} a & c^T \\ b & D \end{bmatrix} = A$$

这即为矩阵 A 的 LU 分解 □

推论 1.17. (矩阵正定性充要条件) 矩阵 A 的所有顺序主子式均正的充要条件为在矩阵 A 的 LU 分解中, 矩阵 U 对角元素为正

1.17 Разложение Холецкого и условия его существования

定义 1.15. (*Cholesky* 分解) 设矩阵 C 为一个对角元素均为正数的下三角矩阵, 则称 $A = CC^*$ 为 **Cholesky 分解** (*разложение Холецкий*)

定理 1.18. (*Cholesky* 分解存在充要条件) 矩阵 $A \in \mathbb{C}^{n \times n}$ 存在 *Cholesky* 分解的充要条件为矩阵 A 为顺序主子式均为正数的 *Hermite* 矩阵

证明. 必要性显然。充分性: 令矩阵 $A = LDL^*, D = \text{diag}(d_1, \dots, d_n)$ 。假定 $C = L \text{diag}(\sqrt{d_1}, \dots, \sqrt{d_n})$, 则有 $A = CC^*$ $\square$

例题 1.5. (*Cholesky* 算法) 不妨令 $n = 3$, 即有

$$\begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} c_{11} & 0 & 0 \\ c_{21} & c_{22} & 0 \\ c_{31} & c_{32} & c_{33} \end{bmatrix} \cdot \begin{bmatrix} c_{11} & c_{21} & c_{31} \\ 0 & c_{22} & c_{32} \\ 0 & 0 & c_{33} \end{bmatrix}$$

再依次将第一个矩阵的元素乘以第二个矩阵的第 1, 2, 3 列, 则有

$$\begin{aligned} c_{11} &= \sqrt{a_{11}}, & c_{21} &= \frac{a_{21}}{c_{11}}, & c_{31} &= \frac{a_{31}}{c_{11}} \\ c_{22} &= \sqrt{a_{22} - c_{21}^2}, & c_{32} &= \frac{a_{32} - c_{31}c_{21}}{c_{22}} \\ c_{33} &= \sqrt{a_{33} - c_{31}^2 - c_{32}^2} \end{aligned}$$

1.18 QR-разложение матрицы

定义 1.16. (方阵 QR 分解) 设方阵 $A \in \mathbb{C}^{n \times n}$, 则称 $A = QR$ 为矩阵 A 的 **QR 分解** (**QR-разложение**), 其中 Q 为酉矩阵, R 为上三角矩阵

命题 1.1. 设方阵 A 的 QR 分解为 $A = QR$, 则有估计

$$\max_{i,j} |r_{ij}| \leq \max_{i,j} q_i^* a_j \leq \|a_j\|_2 \leq \sqrt{n} \max_{i,j} |a_{ij}|$$

证明. 由 $R = Q^*A$ 即得

□

定理 1.19. (方阵 QR 分解存在性) 任意方阵 A 都存在 QR 分解

证明. 设矩阵 A 为非退化矩阵, 则矩阵 A^*A 为正定矩阵, 并且 A^*A 中的所有顺序主子矩阵也都为正定矩阵, 则由 Cholesky 分解存在充要条件 (1.18) 存在 Cholesky 分解: $A^*A = R^*R$, 其中 R 为对角元都为正数的上三角矩阵。下证矩阵 $Q = AR^{-1}$ 为酉矩阵, 这时有

$$Q^*Q = (AR^{-1})^* (AR^{-1}) = (R^{-1})^* (A^*A) R^{-1} = (R^{-1})^* R^*RR^{-1} = I$$

若矩阵 A 为退化矩阵, 则对任意充分大的 $n \in \mathbb{N}$, 扰动矩阵 $A_n = A + \frac{1}{n}I$ 非退化。令 $\lambda_1, \dots, \lambda_k$ 为矩阵 A 的全部 (不重复) 特征值, 且 $\lambda_1 = 0$, 则矩阵 A_n 的特征值形如 $\frac{1}{n}, \lambda_2 + \frac{1}{n}, \dots, \lambda_k + \frac{1}{n}$ 且对于充分小的 n 都不等于 0

由酉矩阵 Q_n 集合为紧集 (关于范数 ($\|Q\|_2 = 1$), 则有界, 构成一个闭集, 且位于有限维空间 $\mathbb{C}^{n \times n}$ 上。则可找到子序列 $Q_{n_k} \xrightarrow{k \rightarrow \infty} Q$, 而极限矩阵 Q 为酉矩阵, 则有 $Q_{n_k}^* A_{n_k} \rightarrow Q^*A = R$ 。矩阵 R 为上三角矩阵, 因为矩阵 $Q_{n_k}^* A_{n_k}$ 中的每一个都为上三角矩阵。则矩阵 A_n 存在 QR 分解: $A_n = Q_n R_n$ 。

□

1.19 反射矩阵及其基本性质

定义 1.17. (反射矩阵) 设 $w \in \mathbb{C}^n$ 并有 $w^*w = 1$, 称矩阵 $H(w) = I - 2ww^*$ 为 **Householder** 矩阵 ((*матрица Хаусхолдера*)) 或反射矩阵 (*матрица отражения*)

性质 1.3. (反射矩阵性质) 反射矩阵 H 满足下列命题:

- 1) 若矩阵 H 为酉矩阵, 则有 $HH^* = (I - 2uu^*)(I - 2uu^*)^* = I - 4uu^* + 4u(u^*u)u^* = I$
- 2) 若矩阵 H 为 *Hermite* 矩阵, 则有 $H^* = H$
- 3) $(\forall v \perp u) : Hu = -u, Hv = v$

定理 1.20. 对任意相同长度的向量 $a, b \in \mathbb{C}^n$, 存在数 γ 和 *Householder* 矩阵 H 满足

$$Ha = \gamma b, \quad |\gamma| = 1$$

证明. 从方程 $Ha = a - 2u(u^*a) = \gamma b$ 中找到合适的向量 u 。若 a 和 b 为两个非零共线向量, 则可取 $u = \frac{a}{\|a\|_2}, \gamma = \pm 1$, 否则假定 $u = \frac{a - \gamma b}{\|a - \gamma b\|_2}$ 代入后得

$$2(u^*a) = \|a - \gamma b\|_2 \Leftrightarrow 2(a^*a - \gamma^*b^*a) = \|a - \gamma b\|_2^2 = \|a\|_2^2 + \|b\|_2^2 - 2\operatorname{Re}(\gamma^*b^*a)$$

又由 $\|a\|_2 = \|b\|_2$, 则有

$$\gamma^*b^*a = \operatorname{Re}(\gamma^*b^*a) \Leftrightarrow \gamma^*b^*a \in \mathbb{R}$$

则当 $b^*a = 0$ 时, 可任意取定 $\gamma : |\gamma| = 1$, 否则 $\gamma = \pm \frac{b^*a}{|b^*a|}$ □

推论 1.21. (方阵 *QR* 分解等价命题辅助推论) 对任意的 $a \in \mathbb{C}^n$ 都存在 *Householder* 矩阵 H 满足

$$Ha = \gamma [\|a\|_2, 0, \dots, 0]^T, \quad |\gamma| = 1$$

注: 这时, 矩阵 H 被向量 $u = \frac{v}{\|v\|_2}$ 定义, 其中 $v = [a_1 - \gamma\|a\|_2, a_2, \dots, a_n]^T$ 。若 $a_1 \neq 0$, 则取 $\gamma = -\frac{a_1}{|a_1|}$

推论 1.22. (方阵 *QR* 分解等价命题) 对任意矩阵 $A \in \mathbb{C}^{n \times n}$ 都存在 *Householder* 矩阵 $H_1, \dots, H_{n-1}$ 满足矩阵 $R = H_{n-1} \dots H_1 A$ 为上三角矩阵

证明. 这里矩阵 H_i 由向量 u_i 定义, 且向量 u_i 的前 $i-1$ 个分量为 0, 即 $u_i^T = [0, \dots, 0, *, \dots, *]$ 。这样的向量指定了一个不会改变自变量前 $i-1$ 个坐标的 *Householder* 矩阵。此外, 假设取定向量 u_i 可以把矩阵 $H_{i-1} \dots H_1 A$ 第 i 列的第 $i+1, i+2, \dots, n$ 个元素变为零, 则得到一个上三角矩阵 □

注: 酉矩阵的乘积为酉矩阵, 则 $Z = H_{n-1} \dots H_1$ 为酉矩阵, $A = QR, Q = Z^*$ 。也就得到了方阵 *QR* 分解的等价推导

注意 1.3. (方阵 QR 分解计算复杂度) 若使用 *Householder* 矩阵或 *Givens* 矩阵, 则 $\tilde{Q}$ 、 $\tilde{R}$ 的实际计算满足

$$\|A - \tilde{Q}\tilde{R}\| \leq c_1(n)\eta\|A\| + \mathcal{O}(\eta^2), \quad \|\tilde{Q}^*\tilde{Q} - I\| \leq c_2(n)\eta + \mathcal{O}(\eta^2)$$

其中 $c_1(n)$ 和 $c_2(n)$ 为 n 的一些函数, 取决于所使用的范数和算法实现的特征

为了使用 *Householder* 矩阵得到方阵的 QR 分解需要 $\frac{4}{3}n^3 + \mathcal{O}(n^2)$ 次算术运算。而为了使用 *Givens* 矩阵得到方阵的 QR 分解需要 $2n^3 + \mathcal{O}(n^2)$ 次算术运算

1.20 Матрица вращения и её основные свойства

定义 1.18. (*Givens* 矩阵) 设矩阵 $G_{kl} \in \mathbb{R}^{n \times n}$ 和单位矩阵仅有位于第 k, l 行第 k, l 列交叉处元素构成的 2×2 子矩阵不同, 且形如

$$M(\varphi) = \begin{bmatrix} \cos(\varphi) & -\sin(\varphi) \\ \sin(\varphi) & \cos(\varphi) \end{bmatrix}$$

则称该矩阵为旋转矩阵 (*матрица вращения*) 或 *Givens* 矩阵 (*матрица Гивенса*)

性质 1.4. (*Givens* 矩阵正交性) *Givens* 矩阵 G_{kl} 为正交矩阵, 亦即满足 $G_{kl}G_{kl}^T = I$

注意 1.4. (*Givens* 矩阵方阵 QR 分解) 若向量 $[a_1, a_2]^T \in \mathbb{R}^2$ 非零, 且

$$\cos(\varphi) = \frac{a_1}{\sqrt{a_1^2 + a_2^2}}, \quad \sin(\varphi) = -\frac{a_2}{\sqrt{a_1^2 + a_2^2}}$$

则对应 *Givens* 矩阵能删除向量的第二个分量: $M(\varphi)[a_1, a_2]^T = [\alpha, 0]^T, \alpha = \sqrt{a_1^2 + a_2^2}$

基于旋转消元法 (*метод исключения элементов с помощью вращений*) 得到矩阵 A 的 QR 分解: 矩阵 A 左乘旋转矩阵 G_{kl} 可以在位于第 k 或第 l 行, 第 k 或第 l 列任意位置得到 0。亦即矩阵 A 可通过左乘旋转矩阵序列的方式化简成上三角阵 R

$$G_{n,n-1} \dots G_{n1} \dots G_{31} G_{21} A = R$$

其中, 矩阵 G_{ij} 将 (i, j) 位置的元素归零

注意 1.5. (方阵 QR 分解计算复杂度) 若使用 *Householder* 矩阵或 *Givens* 矩阵, 则 $\tilde{Q}$ 、 $\tilde{R}$ 的实际计算满足

$$\|A - \tilde{Q}\tilde{R}\| \leq c_1(n)\eta\|A\| + \mathcal{O}(\eta^2), \quad \|\tilde{Q}^*\tilde{Q} - I\| \leq c_2(n)\eta + \mathcal{O}(\eta^2)$$

其中 $c_1(n)$ 和 $c_2(n)$ 为 n 的一些函数, 取决于所使用的范数和算法实现的特征

为了使用 *Householder* 矩阵矩阵得到方阵的 QR 分解需要 $\frac{4}{3}n^3 + \mathcal{O}(n^2)$ 次算术运算。而为了使用 *Givens* 矩阵得到方阵的 QR 分解需要 $2n^3 + \mathcal{O}(n^2)$ 次算术运算

1.21 Кoeffициент перекоса матрицы

定义 1.19. (偏斜系数) 设矩阵 A 的特征向量能构成一个基, λ_i 为矩阵 A 的简单特征值, x_i 为对应的特征向量。若稍微改动矩阵 A 的元素, 则精确到二阶小量的特征值及其对应的特征向量的扰动满足线性方程

$$A \cdot \Delta x_i + \Delta A \cdot x_i \approx \Delta \lambda_i \cdot x_i + \lambda_i \cdot \Delta x_i$$

再利用无扰动特征向量分解 Δx_i 即得 $\Delta x_i = \sum_{j=1}^n \xi_{ij} x_j$, 而一个扰动的特征向量最多确定一个因数, 并取该因数使得 $\xi_{ii} = 0$

下令 y_j 为矩阵 A^* 的对应的特征向量, 亦即 $A^* y_j = \lambda_j^* y_j$, 则有

$$(\forall j) : \langle y_j, A \cdot \Delta x_i \rangle = \langle A^* y_j, \Delta x_i \rangle = \lambda_j^* \langle y_j, \Delta x_i \rangle$$

$$0 = \langle y_j, A x_i \rangle - \langle A^* y_j, x_i \rangle = \langle y_j, \lambda_i x_i \rangle - \langle \lambda_j^* y_j, x_i \rangle \Rightarrow (\lambda_i^* - \lambda_j^*) \langle y_j, x_i \rangle = 0$$

而若 $\lambda_i \neq \lambda_j$ 即得 $\langle y_j, x_i \rangle = 0$

将线性方程乘 y_i , 再当 $j \neq i$ 时乘 y_j 且代入 Δx_i 基向量 $x_1, \dots, x_n$ 下的分解即得

$$\langle y_i, x_i \rangle \Delta \lambda_i \approx \langle y_i, \Delta A \cdot x_i \rangle, \quad \xi_{ij} (\lambda_j - \lambda_i) \langle y_j, x_j \rangle \approx \langle y_j, \Delta A \cdot x_i \rangle$$

由于矩阵 ΔA 的扰动任意, 特征值和特征向量的分量的最大误差不超过 (精确到较高阶小量的被舍弃的无穷小项) 下面的值

$$|\Delta \lambda_i| \lesssim |\chi_i| \cdot \max_{i,j} |(\Delta A)_{ij}|, \quad |\xi_{ij}| \lesssim \frac{|\chi_j| \cdot \|x_i\|_2}{|\lambda_i - \lambda_j| \cdot \|x_j\|_2} \cdot \max_{i,j} |(\Delta A)_{ij}|$$

其中 χ_i 为矩阵的偏斜系数 (коэффициент перекоса):

$$\chi_i = \frac{\|x_i\|_2 \cdot \|y_i\|_2}{\langle x_i, y_i \rangle} = \frac{1}{\cos(\varphi_i)}, \quad |\chi_i| \geq 1$$

φ 为矩阵 A 和 A^* 对应特征向量之间的夹角

例题 1.6. (偏斜系数) 对于 *Hermite* 矩阵 $A = A^*$, 其偏斜系数等于 1, 因为对应的向量一致。换言之, *Hermite* 矩阵的特征值对矩阵元素的扰动不敏感

例题 1.7. (偏斜系数) 假设矩阵 $A \in \mathbb{C}^{2 \times 2}$ 有 *Jordan* 块的形式:

$$A = \begin{bmatrix} a & 1 \\ 0 & a \end{bmatrix}, x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, A^* = \begin{bmatrix} a^* & 0 \\ 1 & a^* \end{bmatrix}, y_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

则 $\langle x_1, y_1 \rangle = 0$ 且偏斜系数等于无穷大 ∞

注意 1.6.（偏斜系数与特征值稳定性）若矩阵对应的偏斜系数较小，则矩阵特征值相对于矩阵元素的扰动稳定；若偏斜系数较大，则稳定性可能会很差。若所有的偏斜系数都较小，则特征向量关于矩阵的所有元素都稳定

1.22 Метод поиска характеристического многочлена трёхдиагональной матрицы

例题 1.8. (三对角线矩阵特征多项式) 令矩阵 $A = (a_{ij}) \in \mathbb{C}^{n \times n}$ 为三对角线矩阵, 则其特征多项式可在不使用插值公式的情况下高效计算, 并且不用多次计算矩阵的行列式

令 $D_k(\lambda)$ 为矩阵 $A - \lambda I$ 的 k 阶主子式, 则 $D_n(\lambda) = f(\lambda)$ 。对于 $k = 3, \dots, n$, 通过最后一行展开行列式 $D_k(\lambda)$ 即得

$$D_k(\lambda) = (a_{kk} - \lambda) D_{k-1}(\lambda) - a_{k,k-1} B_{k,k-1}(\lambda)$$

再通过最后一列展开行列式即得 $B_{k,k-1}(\lambda) = a_{k-1,k} D_{k-2}(\lambda)$, 则

$$D_k(\lambda) = (a_{kk} - \lambda) D_{k-1}(\lambda) - a_{k,k-1} a_{k-1,k} D_{k-2}(\lambda)$$

这表明可以计算 $D_1(\lambda), D_2(\lambda)$ 并使用递推关系来计算 $D_n(\lambda)$

注: 对准三角矩阵, 也可以写出递推关系以便更有效地计算特征多项式

1.23 Метод обратной итерации

定义 1.20. (逆迭代法) 设 λ_i 为矩阵 A 的特征值, $\tilde{\lambda}_i$ 为特征值对应近似值, 则得 $\det(A - \tilde{\lambda}_i I) \neq 0$, 但该行列式的值很小, 这意味着不能从线性方程组 $(A - \tilde{\lambda}_i I)x = \theta$ 中求出对应的特征向量 (该方程组有唯一解 $x = \theta$)

逆迭代法 (метод обратной итерации) 寻找特征向量: 取定任意向量 b 并考虑线性方程组 $(A - \tilde{\lambda}_i I)x = b$ 。假设 n 阶矩阵 A 有 n 个线性无关的特征向量 x_j , 且满足 $(\forall j \in \overline{1;n}) : Ax_j = \lambda_j x_j$ 。通过基 x_j 分解 x 和 b 即得

$$x = \sum_{j=1}^n \xi_j x_j, b = \sum_{j=1}^n \beta_j x_j \Rightarrow \sum_{j=1}^n (\xi_j (\lambda_j - \tilde{\lambda}_i) - \beta_j) x_j = 0$$

因此则有

$$(\forall j \in \overline{1;n}) : \xi_j = \frac{\beta_j}{\lambda_j - \tilde{\lambda}_i}$$

1) λ_i 为简单特征值。则在所有 ξ_j 中, 仅有一个非常大, 则向量 $\frac{x}{\|x\|_2}$ 与 $\frac{x_i}{\|x_i\|_2}$ 几乎相同

2) λ_i 为重特征值, $\lambda_1 = \lambda_2 = \dots = \lambda_p, 1 < p \leq n$ 。在这种情况下特征向量 $x_1, \dots, x_p$ 并不唯一确定。其任意线性组合也为 λ_1 对应的特征向量。这时系数 $\xi_1, \xi_2, \dots, \xi_p$ 将很大, 而其余的系数小。所以找到为 $x_1, \dots, x_p$ 线性组合的向量 x 也就意味着 x 为需求的特征向量

注意 1.7. (逆迭代法) 逆迭代法也可以用于没有一组特征向量能构成基的矩阵

例题 1.9. (逆迭代法) 令 $A = J_4(0)$ 为有特征值 $\lambda = 0$ 的 4 阶 *Jordan* 块。设 $\tilde{\lambda} = \varepsilon, b = [1, 1, 1, 1]^T$, 则在该方法的一次迭代后有:

$$\begin{bmatrix} \varepsilon & 1 & 0 & 0 \\ 0 & \varepsilon & 1 & 0 \\ 0 & 0 & \varepsilon & 1 \\ 0 & 0 & 0 & \varepsilon \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} \varepsilon x_1 + x_2 \\ \varepsilon x_2 + x_3 \\ \varepsilon x_3 + x_4 \\ \varepsilon x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \Rightarrow \begin{cases} x_4 = \varepsilon^{-1} \\ x_3 = -\varepsilon^{-2} + \varepsilon^{-1} \\ x_2 = \varepsilon^{-3} - \varepsilon^{-2} + \varepsilon^{-1} \\ x_1 = -\varepsilon^{-4} + \varepsilon^{-3} - \varepsilon^{-2} + \varepsilon^{-1} \end{cases}$$

将解乘上 $-\varepsilon^4$, 得 $x_1 = 1 + \mathcal{O}(\varepsilon), x_2 = \mathcal{O}(\varepsilon), x_3 = \mathcal{O}(\varepsilon^2), x_4 = \mathcal{O}(\varepsilon^3)$, 即 $x = e_1 + \mathcal{O}(\varepsilon), e_1 = [1, 0, 0, 0]^T$

1.24 Частичная проблема собственных значений. Степенной метод

在很多问题中，并不是对矩阵的所有特征值都感兴趣，而仅仅是其中的一部分。例如，最大模特征值或最小模特征值。若矩阵 A 的维数非常大，则在这种情况下求解矩阵的所有特征值没有意义。搜索单个特征值的大多数方法为迭代法，亦即构造收敛于单个特征值和特征向量的数值序列

定义 1.21. (幂方法) **幂方法 (Степенной метод)** 求矩阵的最大模特征值：令 $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots$ ，构造迭代过程如下。假设矩阵 A 为正规矩阵，则有

$$(s = 0, 1, 2, \dots) : x^{(s+1)} = Ax^{(s)}$$

按矩阵的特征向量分解 0 近似值 $x^{(0)} = \sum_i \xi_i x_i$ 。然后有 $x^{(s)} = \sum_i \lambda_i^s \xi_i x_i$ ，且当 s 足够大时有 $x^{(s)} \approx \lambda_1^s \xi_1 x_1$ 。若 $\xi_1 \neq 0$ ，则向量 $x^{(s)}$ 按方向收敛到特征向量，亦即

$$\exists \lim_{s \rightarrow \infty} \left\| \frac{x^{(s)}}{\|x^{(s)}\|} - \operatorname{sgn}(\xi_1) \frac{x_1}{\|x_1\|} \right\| = 0$$

对于足够大的 s 有 $x^{(s+1)} \approx \lambda_1 x^{(s)}$ 。特征值模即为

$$|\lambda_1| \approx \frac{|x^{(s+1)}|}{|x^{(s)}|}$$

若 $\{x_i\}$ 为由特征向量构成的标准正交基且 $\lambda_1^s > 0$ ，即有

$$\begin{aligned} \left\| \frac{x^{(s)}}{\|x^{(s)}\|} - \operatorname{sgn}(\xi_1) \frac{x_1}{\|x_1\|} \right\|^2 &= \left\| \frac{\sum_i \lambda_i^s \xi_i x_i}{\sqrt{\sum_i (\lambda_i^s \xi_i)^2}} - \operatorname{sgn}(\xi_1) x_1 \right\|^2 \\ &= \left\| \frac{\xi_1 x_1 + \sum_{i>1} \lambda_i^s (\lambda_1)^{-s} \xi_i x_i}{\sqrt{\xi_1^2 + \sum_{i>1} (\lambda_i^s (\lambda_1)^{-s} \xi_i)^2}} - \operatorname{sgn}(\xi_1) x_1 \right\|^2 \\ &\rightarrow \|\operatorname{sgn}(\xi_1) x_1 - \operatorname{sgn}(\xi_1) x_1\| = 0 \end{aligned}$$

这里利用了极限

$$\lambda_i^s (\lambda_1)^{-s} = \left(\frac{\lambda_i}{\lambda_1} \right)^s \xrightarrow{s \rightarrow \infty} 0$$

和范数连续性的性质

1.25 Итерационные методы решения СЛАУ: явные и неявные, одношаговые и многошаговые

定义 1.22. (逐步迭代方法与多步迭代方法) 若迭代方法为算出 $x^{(k+1)}$, 仅需知道前一次迭代的 $x^{(k)}$, 则称迭代方法为逐步迭代方法 (*одношаговый итерационный метод*)。有时也使用, 若 $x^{(k+1)}$ 通过 $x^k, \dots, x^{(k-l)}$ 的数值确定, 则称迭代方法为多步迭代方法 (*многошаговый итерационный метод*)

为了加速收敛, 将数值参数引入迭代方法, 这些参数可能取决于迭代的次数。逐步迭代法标准形式为

$$B^{(k+1)} \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} = b, k = 0, 1, \dots, k^*$$

其中矩阵 $B^{(k+1)}$ 指定一个具体的方法, 称 τ_{k+1} 为迭代参数 (*итерационная параметра*)。假设存在矩阵 $(B^{(k+1)})^{-1}$, 且 $x^{(k+1)}$ 可定义为

$$B^{(k+1)}x^{(k+1)} = F^{(k)}, F^{(k)} = (B^{(k+1)} - \tau_{k+1}A)x^{(k)} + \tau_{k+1}b$$

例题 1.10. (逐步迭代方法) 在 *Jacobi* 迭代方法和 *Gauss-Seidel* 迭代方法中分别输入迭代参数 τ_{k+1} 有

$$\begin{aligned} D \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} &= b \\ (D + A_1) \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} &= b \end{aligned}$$

则这里导出的 *Jacobi* 迭代方法和 *Gauss-Seidel* 迭代方法为逐步迭代方法

定义 1.23. (显式方法与隐式方法) 若迭代方法满足 $B^{(k)} = I$, 则称该迭代方法为显式方法 (*явный метод*), 称其余迭代方法为隐式方法 (*неявный метод*)

注意 1.8. (隐式方法) 隐式方法仅在每一个矩阵 $B^{(k)}$ 都比矩阵 A 本质上更容易求逆的情况下才有意义。例如, 在 *Gauss-Seidel* 迭代方法中矩阵 $B^{(k)}$ 为三角矩阵, 因此更容易求逆。隐式方法的优点为收敛速度更快

例题 1.11. 简单迭代法 (*метод простой итерации*) (显式、稳定的方法):

$$\frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b$$

Richardson 迭代法 (*итерационный метод Ричардсона*) (显式、不稳定的方法):

$$\frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} = b$$

1.26 Каноническая форма одношагового итерационного метода. Метод простой итерации

定义 1.24. (逐步迭代方法与多步迭代方法) 若迭代方法为算出 $x^{(k+1)}$, 仅需知道前一次迭代的 $x^{(k)}$, 则称迭代方法为逐步迭代方法 (*одношаговый итерационный метод*). 有时也使用, 若 $x^{(k+1)}$ 通过 $x^k, \dots, x^{(k-l)}$ 的数值确定, 则称迭代方法为多步迭代方法 (*многошаговый итерационный метод*)

为了加速收敛, 将数值参数引入迭代方法, 这些参数可能取决于迭代的次数。逐步迭代法标准形式为

$$B^{(k+1)} \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} = b, k = 0, 1, \dots, k^*$$

其中矩阵 $B^{(k+1)}$ 指定一个具体的方法, 称 τ_{k+1} 为迭代参数 (*итерационная параметра*)。假设存在矩阵 $(B^{(k+1)})^{-1}$, 且 $x^{(k+1)}$ 可定义为

$$B^{(k+1)} x^{(k+1)} = F^{(k)}, F^{(k)} = (B^{(k+1)} - \tau_{k+1} A) x^{(k)} + \tau_{k+1} b$$

例题 1.12. (逐步迭代方法) 在 *Jacobi* 迭代方法和 *Gauss-Seidel* 迭代方法中分别输入迭代参数 τ_{k+1} 有

$$\begin{aligned} D \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} &= b \\ (D + A_1) \frac{x^{(k+1)} - x^{(k)}}{\tau_{k+1}} + Ax^{(k)} &= b \end{aligned}$$

则这里导出的 *Jacobi* 迭代方法和 *Gauss-Seidel* 迭代方法为逐步迭代方法

例题 1.13. 简单迭代法 (*метод простой итерации*) (显式、稳定的方法):

$$\frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b$$

定理 1.23. (简单迭代方法收敛充要条件) 对于简单迭代方法

$$\frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b, \quad B = I$$

设 A 为正定对称矩阵, $\lambda_i, i = 1, 2, \dots, n$ 为矩阵 A 的特征值。则矩阵 $I - 0.5\tau A$ 的所有特征值均为正为简单迭代方法收敛的充要条件。等价地 $1 - 0.5\tau\lambda_{\max} > 0$, 亦即

$$\tau < \frac{2}{\lambda_{\max}(A)}$$

为简单迭代方法收敛的充要条件

证明. 必要性: 设 $x^{(0)} = x^* + \mu$, 其中 μ 为矩阵 A 的对应于特征值 $\lambda_{\max}$ 的特征向量, 亦即 $A\mu = \lambda_{\max}\mu$, 则 $z^{(0)} = \mu$, 则有

$$z^{(k)} = (I - \tau A)^k z^{(0)} = (I - \tau A)^k \mu \Rightarrow z^{(k)} = (1 - \tau\lambda_{\max})^k \mu, \Rightarrow \|z^{(k)}\| = |1 - \tau\lambda_{\max}|^k \|\mu\|$$

而若 $\tau = 2(\lambda_{\max})^{-1}$, 则 $\|z^{(k)}\| = \|\mu\| \nrightarrow 0$; 若 $\tau > 2(\lambda_{\max})^{-1}$, 则 $\|z^{(k)}\| \rightarrow \infty$ 。充分性同理即证 □

1.27 Критерий сходимости стационарного итерационного метода

定理 1.24. (稳定迭代方法收敛充要条件) 考虑稳定迭代方法

$$B \frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b, \quad B \frac{z^{(k+1)} - z^{(k)}}{\tau} + Az^{(k)} = \theta \Leftrightarrow z^{(k+1)} = Sz^{(k)}$$

则该迭代方法在任意初始近似 $x^{(0)}$ 下收敛的充要条件为矩阵 $S = I - \tau B^{-1}A$ 的特征值 s 都满足 $|s| < 1$

证明. 必要性: 设矩阵 S 有特征值 $s: |s| > 1$, 令 μ 为 s 对应的特征向量, $x^{(0)} = x^* + \mu$, 则有

$$z^{(0)} = \mu, z^{(k)} = S^k z^{(0)} = s^k z^{(0)} = s^k \mu \Rightarrow \|z^{(k)}\| = |s|^k \cdot \|\mu\| \rightarrow \infty$$

充分性: 考虑矩阵 S 有 n 个线性无关特征向量 $\mu_k, k = 1, \dots, n$ 的情况. 令 $s_k, k = 1, 2, \dots, n$ 为对应特征值. 用向量 μ_k 分解初始误差 $z^{(0)} = x^{(0)} - x^*$ 即得

$$z^{(0)} = \sum_{j=1}^n c_j \mu_j \Rightarrow z^{(k)} = S^k z^{(0)} = \sum_{j=1}^n c_j s_j^k \mu_j \Rightarrow \|z^{(k)}\| \leq \rho^k \sum_{j=1}^n |c_j| \cdot \|\mu_j\| \rightarrow 0$$

其中 $\rho = \max_{j=1, \dots, n} |s_j|$ 为矩阵 S 的谱半径, $|\rho| < 1$

在一般情况下, 当矩阵 S 没有由特征向量构成的基, 则构建 Jordan 型: $\tilde{S} = P^{-1}SP$, 这时 $\tilde{S} = \text{diag}(\tilde{S}_1, \dots, \tilde{S}_l)$ 为分块对角矩阵, $\tilde{S}_k$ 为 Jordan 块. 令 Jordan 块 $\tilde{S}_k$ 对应于特征值 s_k

构建改良 Jordan 型: $\hat{S} = D^{-1}\tilde{S}D$, 其中 $D = \text{diag}(1, \varepsilon, \dots, \varepsilon^{n-1}), \varepsilon > 0$. 矩阵 $\hat{S}$ 具有和 $\tilde{S}$ 相同的分块对角型, 但 Jordan 块此时形式为

$$\hat{S}_k = \begin{bmatrix} s_k & \varepsilon & 0 & 0 & \dots & 0 \\ 0 & s_k & \varepsilon & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & 0 & \dots & \varepsilon \\ 0 & 0 & 0 & 0 & \dots & s_k \end{bmatrix}$$

而矩阵 S 和 $\hat{S}$ 由等式 $\hat{S} = Q^{-1}SQ, Q = PD$ 联系. 此外

$$\|\hat{S}\|_{\infty} \leq \rho(S) + \varepsilon, \quad \rho(S) = \max_k |s_k|$$

令 $\|y\|_* = \|Q^{-1}y\|_{\infty}$, 则有

$$\|S\|_* = \max_{y \neq \theta} \frac{\|Sy\|_*}{\|y\|_*} = \max_{y \neq \theta} \frac{\|Q^{-1}Sy\|_{\infty}}{\|Q^{-1}y\|_{\infty}} = \max_{x \neq \theta} \frac{\|Q^{-1}SQx\|_{\infty}}{\|x\|_{\infty}} = \|\hat{S}\|_{\infty} \leq \rho(S) + \varepsilon$$

而由条件 $\rho(S) < 1$, 则

$$(\exists \varepsilon > 0) : \|S\|_* \leq \rho(S) + \varepsilon \leq q < 1$$

则 $\|z^{(k)}\|_* \leq \|S\|_*^k \cdot \|z^{(0)}\|_* \leq q^k \|z^{(0)}\|_*$, 则有当 $k \rightarrow \infty$ 时, $\|z^{(k)}\|_* \rightarrow 0$

□

1.28 Скорость сходимости итерационного метода

定义 1.25. (迭代方法收敛速度) 考虑线性方程组 $Ax = b$ 的迭代方法, 其近似值序列为 $\{x^{(k)}\}, k = 0, 1, 2, \dots$ 。若迭代方法的误差满足

$$(k = 0, 1, 2, \dots, \quad 0 < q < 1) : \|x^{(k)} - x^*\| \leq q^k \|x^{(0)} - x^*\|$$

则称该迭代方法以分母为 q 的几何级数速度收敛。这时

$$(\forall \varepsilon > 0)(\exists k \in \mathbb{N}) : [q^k < \varepsilon \Rightarrow \|x^{(k)} - x^*\| \leq \varepsilon \|x^{(0)} - x^*\|]$$

其中

$$q^k < \varepsilon \Leftrightarrow k \geq K(\varepsilon) = \ln \left(\frac{1}{\varepsilon} \right) \ln \left(\frac{1}{q} \right)^{-1}$$

则称数 $K(\varepsilon)$ 的整数部分为获得给定 ε 精度所需的最小迭代次数 (*минимальный число итераций, необходимый для получения заданной точности ε*)。称 $\ln \left(\frac{1}{q} \right)$ 为迭代方法收敛速度 (*скорость сходимости итерационного метода*)

注意 1.9. (迭代方法收敛速度) 迭代方法收敛速度由过渡矩阵 S 确定, 且不依赖于迭代序号 k 、不依赖于初始近似 $x^{(0)}$ 的选择、也不依赖于给定精度。不同迭代方法的性能通常通过其收敛速度来比较, 亦即 $\ln \left(\frac{1}{q} \right)$ 越大, 迭代方法越好

引理 1.2. (迭代方法误差估计第一引理) 考虑迭代方法

$$B \frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b$$

其误差 $z^{(k)} = x^{(k)} - x^*$ 的方程为

$$B \frac{z^{(k+1)} - z^{(k)}}{\tau} + Az^{(k)} = 0, \quad k = 0, 1, 2, \dots \Leftrightarrow z^{(k+1)} = Sz^{(k)}, S = I - \tau B^{-1}A$$

则有矩阵不等式

$$\frac{1-\rho}{\tau}B \leq A \leq \frac{1+\rho}{\tau}B$$

成立充要条件为对任意 $z^{(0)}$, 迭代方法误差满足估计 $\|z^{(k+1)}\|_A \leq \rho \|z^{(k)}\|_A, k = 0, 1, \dots$

证明. 设 $w^{(k)} = A^{\frac{1}{2}}z^{(k)}, \|w^{(k)}\| = \sqrt{\langle w^{(k)}, w^{(k)} \rangle}$, 则可将误差估计改写为 $\|w^{(k+1)}\| \leq \rho \|w^{(k)}\|$ 。另外 $w^{(k+1)} = \tilde{S}w^{(k)}$, 其中 $\tilde{S} = A^{\frac{1}{2}}SA^{-\frac{1}{2}} = I - \tau C, C = A^{\frac{1}{2}}B^{-1}A^{\frac{1}{2}}$ 。矩阵 $\tilde{S}$ 为对称矩阵, 则

$$\|w^{(k+1)}\|^2 = \langle \tilde{S}w^{(k)}, \tilde{S}w^{(k)} \rangle = \langle \tilde{S}^2 w^{(k)}, w^{(k)} \rangle$$

进而则有

$$\begin{aligned}\tilde{S}^2 \leq \rho^2 I &\Leftrightarrow -\rho I \leq \tilde{S} \leq \rho I \Leftrightarrow \frac{1-\rho}{\tau} I \leq C \leq \frac{1+\rho}{\tau} I \Leftrightarrow \frac{1-\rho}{\tau} C^{-1} \leq I \leq \frac{1+\rho}{\tau} C^{-1} \\ &\Leftrightarrow \frac{1-\rho}{\tau} A^{-1/2} B A^{-1/2} \leq I \leq \frac{1+\rho}{\tau} A^{-1/2} B A^{-1/2} \Leftrightarrow \frac{1-\rho}{\tau} B \leq A \leq \frac{1+\rho}{\tau} B\end{aligned}$$

引理即证 □

引理 1.3. (迭代方法误差估计第二引理) 考虑迭代方法

$$B \frac{x^{(k+1)} - x^{(k)}}{\tau} + A x^{(k)} = b$$

其误差 $z^{(k)} = x^{(k)} - x^*$ 的方程为

$$B \frac{z^{(k+1)} - z^{(k)}}{\tau} + A z^{(k)} = 0, \quad k = 0, 1, 2, \dots \Leftrightarrow z^{(k+1)} = S z^{(k)}, S = I - \tau B^{-1} A$$

则有矩阵不等式

$$\frac{1-\rho}{\tau} B \leq A \leq \frac{1+\rho}{\tau} B$$

成立充要条件为对任意 $z^{(0)}$, 迭代方法误差满足估计 $\|z^{(k+1)}\|_B \leq \rho \|z^{(k)}\|_B, k = 0, 1, \dots$

证明. 设 $w^{(k)} = B^{\frac{1}{2}} z^{(k)}, C = B^{-\frac{1}{2}} A B^{-\frac{1}{2}}$, 则

$$\|z^{(k+1)}\|_B \leq \rho \|z^{(k)}\|_B \Leftrightarrow \|w^{(k+1)}\| \leq \rho \|w^{(k)}\|$$

另外, $w^{(k+1)} = B^{\frac{1}{2}} S B^{-\frac{1}{2}} w^{(k)} = (I - \tau C) w^{(k)}$, 则有

$$\begin{aligned}\|w^{(k+1)}\| \leq \rho \|w^{(k)}\| &\Leftrightarrow \frac{1-\rho}{\tau} I \leq B^{-\frac{1}{2}} A B^{-\frac{1}{2}} \leq \frac{1+\rho}{\tau} I \\ &\Leftrightarrow \frac{1-\rho}{\tau} B^{\frac{1}{2}} A^{-1} B^{\frac{1}{2}} \leq I \leq \frac{1+\rho}{\tau} B^{\frac{1}{2}} A^{-1} B^{\frac{1}{2}} \\ &\Leftrightarrow \frac{1-\rho}{\tau} A^{-1} \leq B^{-1} \leq \frac{1+\rho}{\tau} A^{-1} \Leftrightarrow \frac{1-\rho}{\tau} B \leq A \leq \frac{1+\rho}{\tau} B\end{aligned}$$

引理即证 □

定理 1.25. (迭代方法收敛速度估计) 考虑迭代方法

$$B \frac{x^{(k+1)} - x^{(k)}}{\tau} + Ax^{(k)} = b$$

设 A, B 为正定对称矩阵且有

$$\gamma_1 B \leq A \leq \gamma_2 B, \quad \gamma_1, \gamma_2 > 0, \gamma_2 > \gamma_1$$

则对于 $\tau = \frac{2}{\gamma_1 + \gamma_2}$, 迭代方法收敛且有误差估计

$$\|x^{(k)} - x^*\|_A \leq \rho^k \|x^{(0)} - x^*\|_A, k = 0, 1, 2, \dots$$

$$\|x^{(k)} - x^*\|_B \leq \rho^k \|x^{(0)} - x^*\|_B, k = 0, 1, 2, \dots$$

$$\rho = \frac{1 - \xi}{1 + \xi}, \quad \xi = \frac{\gamma_1}{\gamma_2}$$

证明. 假设

$$\rho = \frac{1 - \xi}{1 + \xi}, \xi = \frac{\gamma_1}{\gamma_2}, \tau = \frac{2}{\gamma_1 + \gamma_2}$$

则有

$$\frac{1 - \rho}{\tau} = \frac{2\xi}{(1 + \xi)\tau} = \frac{\gamma_1 + \gamma_2}{1 + \frac{\gamma_2}{\gamma_1}} = \gamma_1$$

$$\frac{1 + \rho}{\tau} = \frac{2}{(1 + \xi)\tau} = \frac{\gamma_1 + \gamma_2}{1 + \frac{\gamma_1}{\gamma_2}} = \gamma_2$$

由引理 (1.2)(1.3) 即证

□

1.29 一般化特征值问题

定义 1.26. (广义特征值问题与最优迭代参数) 考虑广义特征值问题 (*обобщённая задача на собственные значения*), 亦即 $A\mu = \lambda B\mu$ 。若 $\gamma_1 B \leq A \leq \gamma_2 B$, 则对任意特征向量 μ 有

$$\gamma_1 \langle B\mu, \mu \rangle \leq \langle A\mu, \mu \rangle = \lambda \langle B\mu, \mu \rangle \leq \gamma_2 \langle B\mu, \mu \rangle$$

则有

$$\gamma_1 \leq \lambda_{\min}(A, B), \quad \gamma_2 \geq \lambda_{\max}(A, B), \quad (1.1)$$

其中 $\lambda_{\min}(A, B), \lambda_{\max}(A, B)$ 分别为最小特征值和最大特征值, 则满足不等式 $\gamma_1 B \leq A \leq \gamma_2 B$ 的最精确常量为 $\gamma_1 = \lambda_{\min}(A, B), \gamma_2 = \lambda_{\max}(A, B)$

在满足条件 (1.1) 的参数 γ_1, γ_2 的集合上, 两个变量 $\rho = \frac{1-\xi}{1+\xi}, \xi = \frac{\gamma_1}{\gamma_2}$ 的函数在点

$$\tau_0 = \frac{2}{\lambda_{\min}(A, B) + \lambda_{\max}(A, B)}, \quad \xi = \frac{\lambda_{\min}(A, B)}{\lambda_{\max}(A, B)}$$

处达到最小值。称 τ_0 为最优迭代参数 (*оптимальный итерационный параметр*)

注意 1.10. (最优迭代参数) 注意到

$$\rho(\gamma_1, \gamma_2) = \frac{\gamma_2 - \gamma_1}{\gamma_2 + \gamma_1}, \quad \rho'_{\gamma_1} = \frac{-2\gamma_2}{(\gamma_2 + \gamma_1)^2} < 0, \quad \rho'_{\gamma_2} = \frac{2\gamma_1}{(\gamma_2 + \gamma_1)^2} > 0$$

则函数 $\rho(\gamma_1, \gamma_2)$ 当

$$\gamma_1 = \gamma_{1,\max} = \lambda_{\min}(A, B), \gamma_2 = \gamma_{2,\min} = \lambda_{\max}(A, B)$$

时达到最小值

1.30 Многочлен Чебышёва на отрезке $[-1; 1]$, его свойства

定义 1.27. (*Chebyshev* 多项式) 考虑辅助问题: 在所有首项系数为 1 的 n 次多项式中, 需找到一个多项式 $T_n(x)$, 其对应 $\max_{x \in [-1; 1]} |T_n(x)|$ 最小。称具有此性质的多项式为 ***Chebyshev* 多项式 (многочлен Чебышёва)** 或在闭区间 $[-1; 1]$ 上偏离 0 最小的多项式 (***многочлен, наименее уклоняющимся от нуля на отрезке $[-1; 1]$***)

引理 1.4. 假设存在一个点集 $-1 \leq x'_n < x'_{n-1} < \dots < x'_1 < x'_0 \leq 1$ 满足

$$(\forall k \in \overline{0; n}) : |Q_n(x'_k)| = \|Q_n\| = \max_{x \in [-1; 1]} |Q_n(x)|$$

且 $Q_n(x'_l)$ 符号交错 (*чередующиеся*), 则在所有首项系数为 1 的 n 次多项式中, $Q_n(x)$ 与 0 的偏离最小

证明. 反证: 假设存在首项系数为 1 的 n 次多项式 $\hat{Q}_n(x)$, 使得 $\|\hat{Q}_n\| < \|Q_n\|$, 则有

$$\max_{x \in [-1; 1]} |\hat{Q}_n(x)| < \|Q_n\|$$

下设 $R(x) = Q_n(x) - \hat{Q}_n(x)$, 该多项式次数不超过 $n-1$, 也不恒等于零。再设 $Q_n(x'_k) = (-1)^k \|Q_n\|, k = 0, 1, \dots, n$, 则

$$(\forall k \in \overline{0; n}) : R(x'_k) = (-1)^k \|Q_n\| - \hat{Q}_n(x'_k)$$

而区间 $[-1; 1]$ 上多项式 $R(x)$ 改变符号 n 次, 即其至少有 n 个根, 但由多项式 $R(x)$ 至多为 $n-1$ 次多项式, 矛盾 $\square$

定理 1.26. (*Chebyshev* 多项式) 多项式 $T_n(x) = 2^{1-n} \cos(n \arccos(x)), x \in [-1; 1]$ 为 *Chebyshev* 多项式

证明. 1) 考虑函数 $P_n(x) = \cos(n \arccos(x)), x \in [-1; 1]$, 则有

$$\cos((n+1) \arccos(x)) + \cos((n-1) \arccos(x)) = 2 \cos(n \arccos(x)) \cdot \cos(\arccos(x)) = 2x P_n(x)$$

则有递推关系

$$P_{n+1}(x) - 2x P_n(x) + P_{n-1}(x) = 0, \quad P_0(x) = 1, P_1(x) = x$$

归纳即证, 多形式 $P_n(x)$ 为首项系数为 2^{n-1} 的 n 次多项式, 则 $T_n(x)$ 为首项系数为 1 的 n 次多项式

2) 多项式 $T_n(x)$ 的根位于点

$$x_k = \cos \frac{(2k+1)\pi}{2n}, k = 0, 1, \dots, n-1$$

极值位于点

$$x'_k = \cos \frac{k\pi}{n}, k = 0, 1, \dots, n$$

且有 $T_n(x'_k) = (-1)^k 2^{1-n}, k = 0, 1, \dots, n$, 则 $\max_{x \in [-1;1]} |T_n(x)| = 2^{1-n}$

下证, 在所有首项系数为 1 的 n 次多项式中, 多项式 $T_n(x)$ 在区间 $[-1;1]$ 上与 0 的偏差最小, 亦即证明

$$\max_{x \in [-1;1]} |T_n(x)| = \min \left\{ \max_{x \in [-1;1]} |Q_n(x)| \right\}$$

其中 $Q_n(x)$ 为首项系数为 1 的 n 次多项式, 而 $T_n(x)$ 满足引理 (1.4) 条件, 定理即证 $\square$

1.31 Метод минимальных невязок для решения СЛАУ

定义 1.28. (最小残差方法) 设矩阵 A 为一个正定对称矩阵, $r^{(k)} = (Ax^{(k)} - b)$ 为第 k 次迭代的残差 (невязка)。误差 $z^{(k)}$ 和残差 $r^{(k)}$ 满足等式 $Az^{(k)} = r^{(k)}$ 。此外将显式迭代方法改写为 $x^{(k+1)} = x^{(k)} - \tau_{k+1}r^{(k)}$ 的形式

最小残差方法 (Метод минимальных невязок): 参数 τ_{k+1} 从给定范数 $\|r^{(k)}\|$ 下, $\|r^{(k+1)}\|$ 取最小值的条件中选择, 得到关于迭代参数 τ_{k+1} 的显式表达式

$$Ax^{(k+1)} = Ax^{(k)} - \tau_{k+1}Ar^{(k)} \Rightarrow r^{(k+1)} = r^{(k)} - \tau_{k+1}Ar^{(k)}$$

即残差满足和误差相同的方程 $z^{(k)} = x^{(k)} - x^*$, 于是

$$\|r^{(k+1)}\|^2 = \|r^{(k)}\|^2 - 2\tau_{k+1}\langle r^{(k)}, Ar^{(k)} \rangle + \tau_{k+1}^2 \|Ar^{(k)}\|^2$$

当 $\tau_{k+1} = \tau_{k+1}^* = \frac{\langle Ar^{(k)}, r^{(k)} \rangle}{\|Ar^{(k)}\|^2}$ 时, $\|r^{(k+1)}\|$ 达到最小值

注意 1.11. (最小残差方法) 在最小残差方法中, 从第 k 次迭代到第 $k+1$ 次迭代实现方式为

- 1) 根据找到的 $x^{(k)}$ 的值计算残差向量 $r^{(k)} = Ax^{(k)} - b$
- 2) 根据指定公式, 有 $\tau_{k+1} = \tau_{k+1}^*$
- 3) 根据迭代方法基本方程计算 $x^{(k+1)}$

最小残差法以不低于具有最优参数 τ 的简单迭代法的速度收敛

定理 1.27. (最小残差方法误差估计) 设矩阵 A 为正定对称矩阵, 则最小残差法的误差满足估计

$$(n = 0, 1, \dots) : \|A(x^{(n)} - x^*)\| \leq \rho_0^n \|A(x^{(0)} - x^*)\|$$

其中

$$\rho_0 = \frac{1 - \xi}{1 + \xi}, \quad \xi = \frac{\lambda_{\min}(A)}{\lambda_{\max}(A)}$$

证明. 若在代替最小化值 τ_{k+1}^* 的等式中

$$\|r^{(k+1)}\|^2 = \|r^{(k)}\|^2 - 2\tau_{k+1} \langle r^{(k)}, Ar^{(k)} \rangle + \tau_{k+1}^2 \|Ar^{(k)}\|^2$$

取 $\tau_{k+1} = \tau_0 = \frac{2}{\lambda_{\min}(A) + \lambda_{\max}(A)}$, 则有不等式

$$\|r^{(k+1)}\|^2 \leq \|(I - \tau_0 A)r^{(k)}\|^2 \Rightarrow \|r^{(k+1)}\| \leq \|I - \tau_0 A\| \cdot \|r^{(k)}\|, \quad \|r^{(k)}\| = \|z^{(k)}\|_A$$

由迭代方法误差估计 (??) 有

$$\|I - \tau_0 A\| = \sigma_{\max}(I - \tau_0 A) = \rho_0 = \frac{1 - \xi}{1 + \xi}, \quad \xi = \frac{\lambda_{\min}(A)}{\lambda_{\max}(A)}$$

则有 $\|r^{(k+1)}\| \leq \rho_0 \|r^{(k)}\| \Rightarrow \|A(x^{(k+1)} - x^*)\| \leq \rho_0 \|A(x^{(k)} - x^*)\|$, 定理得证 $\square$

1.32 Метод минимальных поправок для решения СЛАУ

定义 1.29. (最小校正方法) 考虑隐式迭代方法

$$x^{(k+1)} = x^{(k)} - \tau B^{-1} r^{(k)}, r^{(k)} = Ax^{(k)} - b$$

则称向量 $w^{(k)} = B^{-1} r^{(k)}$ 为第 $k+1$ 次迭代的校正 (*поправка*)。校正满足隐式方法下与误差 $z^{(k)} = x^{(k)} - x^*$ 相同的方程

$$B \frac{w^{(k+1)} - w^{(k)}}{\tau_{k+1}} + Aw^{(k)} = 0$$

设矩阵 B 为正定对称矩阵。最小校正方法 (*метод минимальных поправок*): 隐式迭代方法, 其中参数 τ_{k+1} 从对给定的 $w^{(k)}$ 使 $\|w^{(k+1)}\|_B = \langle Bw^{(k+1)}, w^{(k+1)} \rangle^{\frac{1}{2}}$ 最小的条件中选择。在 $B = I$ 的情况下, 最小校正方法和最小残差方法全等。重写校正方程为

$$w^{(k+1)} = w^{(k)} - \tau_{k+1} B^{-1} Aw^{(k)}$$

$$\|w^{(k+1)}\|_B^2 = \|w^{(k)}\|_B^2 - 2\tau_{k+1} \langle Aw^{(k)}, w^{(k)} \rangle + \tau_{k+1}^2 \langle B^{-1} Aw^{(k)}, Aw^{(k)} \rangle$$

若 $\tau_{k+1} = \tau_{k+1}^* = \frac{\langle Aw^{(k)}, w^{(k)} \rangle}{\langle B^{-1} Aw^{(k)}, Aw^{(k)} \rangle}$, 校正 $\|w^{(k+1)}\|_B$ 将为最小的,

注意 1.12. (最小校正方法) 在每次迭代的最小校正方中, 需要:

- 1) 求解线性方程组 $Bw^{(k)} = r^{(k)}$ 并求校正 $w^{(k)}$
- 2) 求解线性方程组 $Bv^{(k)} = Aw^{(k)}$ 并求向量 $v^{(k)} = B^{-1} Aw^{(k)}$
- 3) 计算 τ_{k+1}

最小校正方法的收敛速度由广义特征值问题 $Ax = \lambda Bx$ 的谱的边界决定

定理 1.28. (最小校正方法误差估计) 设 A, B 为正定对称矩阵, $\lambda_{\min}(B^{-1}A), \lambda_{\max}(B^{-1}A)$ 分别为广义特征值问题的最小特征值和最大特征值, 则最小校正方法的误差满足估计

$$\|A(x^{(n)} - x^*)\|_{B^{-1}} \leq \rho_0^n \cdot \|A(x^{(0)} - x^*)\|_{B^{-1}}, n = 0, 1, \dots$$

$$\rho_0 = \frac{1 - \xi}{1 + \xi}, \xi = \frac{\lambda_{\min}(B^{-1}A)}{\lambda_{\max}(B^{-1}A)}$$

证明. 设 $v^{(k)} = B^{\frac{1}{2}}w^{(k)}, C = B^{-\frac{1}{2}}AB^{-\frac{1}{2}}$, 则有

$$\frac{v^{(k+1)} - v^{(k)}}{\tau_{k+1}} + Cv^{(k)} = 0, \quad \tau_{k+1}^* = \frac{\langle Cv^{(k)}, v^{(k)} \rangle}{\|Cv^{(k)}\|^2}$$

由定理 (1.27) 可类似得到

$$\|v^{(k+1)}\| \leq \rho_0 \|v^{(k)}\|, \rho_0 = \frac{1 - \xi}{1 + \xi}, \xi = \frac{\lambda_{\min}(C)}{\lambda_{\max}(C)}$$

而 $\lambda_{\min}(C) = \lambda_{\min}(B^{-1}A), \lambda_{\max}(C) = \lambda_{\max}(B^{-1}A)$, 此外

$$\|v^{(k)}\| = \|B^{1/2}w^{(k)}\| = \|B^{-1/2}r^{(k)}\| = \|r^{(k)}\|_{B^{-1}} = \|A(x^{(k)} - x^*)\|_{B^{-1}}$$

定理即证 □

1.33 Метод сопряжённых градиентов для решения СЛАУ

注意 1.13. (共轭梯度方法) 共轭梯度方法为一个两步迭代方法, 即为了求出新的迭代 $x^{(k+1)}$, 要使用前面两次迭代 $x^{(k)}$ 和 $x^{(k-1)}$ 。在正确选择参数的情况下, 收敛速度将高于一步迭代法。特别地, 所考虑的共轭梯度方法在任何初始近似下, 都在有限次迭代中收敛

定义 1.30. (共轭梯度方法) 设 A 为一个系统矩阵 (*матрица системы*), B 为正定对称矩阵。考虑隐式两步迭代方法

$$B \frac{(x^{(k+1)} - x^{(k)}) + (1 - \alpha_{k+1})(x^{(k)} - x^{(k-1)})}{\tau_{k+1}\alpha_{k+1}} + Ax^{(k)} = b, k = 1, 2, \dots$$

其中 α_{k+1}, τ_{k+1} 为迭代参数。需指定两个初始近似值 $x^{(0)}$ 和 $x^{(1)}$, 初始近似值 $x^{(0)}$ 可任意取定, 而向量 $x^{(1)}$ 要通过一步公式计算 (当 $k = 0, a_1 = 1$), 亦即

$$B \frac{x^{(1)} - x^{(0)}}{\tau_1} + Ax^{(0)} = b$$

若找到参数 α_{k+1}, τ_{k+1} , 则新的近似值 $x^{(k+1)}$ 通过前面的两个值 $x^{(k)}$ 和 $x^{(k-1)}$ 表出, 即

$$x^{(k+1)} = \alpha_{k+1}x^{(k)} + (1 - \alpha_{k+1})x^{(k-1)} - \tau_{k+1}\alpha_{k+1}w^{(k)}$$

其中 $w^{(k)} = B^{-1}r^{(k)}, r^{(k)} = Ax^{(k)} - b$

注意 1.14. (共轭梯度方法误差最小化) 共轭梯度方法误差 $z^{(k)} = x^{(k)} - x^*$ 满足方程

$$z^{(k+1)} = \alpha_{k+1} (I - \tau_{k+1} B^{-1} A) z^{(k)} + (1 - \alpha_{k+1}) z^{(k-1)}, k = 1, 2, \dots, \quad z^{(1)} = (I - \tau_1 B^{-1} A) z^{(0)}$$

下设 $v^{(k)} = A^{\frac{1}{2}} z^{(k)}$, $\|v^{(k)}\| = \|z^{(k)}\|_A$, $C = A^{\frac{1}{2}} B^{-1} A^{\frac{1}{2}}$, 函数 $v^{(k)}$ 满足方程

$$v^{(k+1)} = \alpha_{k+1} (I - \tau_{k+1} C) v^{(k)} + (1 - \alpha_{k+1}) v^{(k-1)}, k = 1, 2, \dots, \quad v^{(1)} = (I - \tau_1 C) v^{(0)}$$

再设矩阵 A 和 B 为正定对称矩阵且满足不等式

$$\gamma_1 B \leq A \leq \gamma_2 B, \gamma_2 > \gamma_1 > 0$$

则 $C = C^T > 0$ 且 $\gamma_1 I \leq C \leq \gamma_2 I$ 。换言之, 若依次求得向量 $v^{(1)}, v^{(2)}, \dots, v^{(k-1)}$, 则得到 $v^{(k)} = P_k(C)v^{(0)}$, 其中 $P_k(C)$ 为算子 C 对应的满足条件 $P_k(0) = I$ 的 k 次矩阵多项式

需选择合适的迭代参数 τ_k, α_k , 以便于对任意 $n = 1, 2, \dots$, $\|v^{(n)}\| = \|z^{(n)}\|_A$ 最小。参数 τ_1 为从对给定的向量 $v^{(0)}$ 使 $\|v^{(1)}\|$ 取最小值的条件中求得, 即 $\tau_1 = \frac{\langle Cv^{(0)}, v^{(0)} \rangle}{\|Cv^{(0)}\|^2}$ 。注意, 参数 τ_1 满足 $\langle Cv^{(1)}, v^{(0)} \rangle = 0$

假设 $\alpha_1 = 1$ 。考虑在第 k 次迭代的误差 $v^{(k)} = P_k(C)v^{(0)}$ 。将多项式 $P_k(C)$ 写为

$$P_k(C) = I + \sum_{i=1}^k a_i^{(k)} C^i, a_i^{(k)} = a_i^{(k)}(\alpha_i, \tau_i), i = 1, 2, \dots, k$$

则有

$$v^{(k)} = v^{(0)} + \sum_{i=1}^k a_i^{(k)} C^i v^{(0)}, k = 1, 2, \dots$$

$$\|v^{(n)}\|^2 = \sum_{i,j=1}^n a_i^{(n)} a_j^{(n)} \langle C^i v^{(0)}, C^j v^{(0)} \rangle + 2 \sum_{j=1}^n a_j^{(n)} \langle v^{(0)}, C^j v^{(0)} \rangle + \|v^{(0)}\|^2$$

则 $\|v^{(n)}\|^2$ 为关于变量 $a_1^{(n)}, \dots, a_n^{(n)}$ 的二次多项式。令导数 $\frac{\partial \|v^{(n)}\|^2}{\partial a_j^{(n)}}, j = 1, 2, \dots, n$ 等于 0, 则得关于 $a_i^{(n)}$ 的方程组

$$\sum_{i=1}^n a_i^{(n)} \langle C^j v^{(0)}, C^i v^{(0)} \rangle + \langle C^j v^{(0)}, v^{(0)} \rangle = 0$$

其解与最小值 $\|v^{(n)}\|^2$ 对应

使用已获得的方程, 现需找到参数 $\alpha_k, \tau_k, k = 1, 2, \dots, n$ 。注意, 搜索 $a_i^{(n)}$ 的方程可写为

$$(j = 1, 2, \dots, n) : \langle C^j v^{(0)}, v^{(n)} \rangle = 0$$

引理 1.5. 条件

$$(j = 1, 2, \dots, n) : \langle C^j v^{(0)}, v^{(n)} \rangle = 0$$

等价于条件

$$\langle C v^{(j)}, v^{(n)} \rangle = 0, j = 0, 1, \dots, n-1$$

证明. 从条件 $\langle C v^{(j)}, v^{(n)} \rangle = 0, n = 1, 2, \dots, j = 0, 1, \dots, n-1$ 中求出迭代参数, 亦即向量 $v^{(0)}, v^{(1)}, \dots, v^{(k)}, \dots$ 在标量积 $\langle u, v \rangle_C = \langle Cu, v \rangle$ 的意义上两两正交

假设参数 $\tau_1, \tau_2, \dots, \tau_k, \alpha_1, \alpha_2, \dots, \alpha_k$ 已经为最优选择。由

$$\langle C v^{(j)}, v^{(k+1)} \rangle = 0, j = 0, 1, \dots, k$$

构造最优的参数 τ_{k+1}, α_{k+1} 。则若取

$$\tau_{k+1} = \frac{\langle C v^{(k)}, v^{(k)} \rangle}{\|C v^{(k)}\|^2}, \quad \alpha_{k+1} = \left(1 - \frac{\tau_{k+1}}{\tau_k} \cdot \frac{1}{\alpha_k} \cdot \frac{\langle C v^{(k)}, v^{(k)} \rangle}{\langle C v^{(k-1)}, v^{(k-1)} \rangle} \right)^{-1}$$

则指定等式满足。另外, 注意到

$$\begin{aligned} v^{(k)} &= A^{\frac{1}{2}} z^{(k)}, C = A^{\frac{1}{2}} B^{-1} A^{\frac{1}{2}}, z^{(k)} = x^{(k)} - x^*, Az^{(k)} = Ax^{(k)} - b = r^{(k)}, B^{-1} r^{(k)} = w^{(k)} \\ C v^{(k)} &= A^{1/2} w^{(k)}, \langle C v^{(k)}, v^{(k)} \rangle = \langle w^{(k)}, r^{(k)} \rangle, \langle C v^{(k)}, C v^{(k)} \rangle = \langle A w^{(k)}, w^{(k)} \rangle \end{aligned}$$

引理即证 □

1.34 Псевдообратная матрица и её использование для решения СЛАУ

定义 1.31. (Moore-Penrose 伪逆矩阵) 考虑矩阵方程 $AXA = A$, 若矩阵 A 为方阵且非退化, 则该方程有唯一解 $X = A^{-1}$ 。若矩阵 A 为任意 $m \times n$ 形长方形矩阵, 则所求的解为 $n \times m$ 形矩阵, 且不唯一确定。一般情况下, 方程有无穷解集

若满足条件

$$AA^+A = A, \quad A^+ = UA^* = A^*V$$

其中矩阵 $U \in \mathbb{C}^{n \times n}, V \in \mathbb{C}^{m \times m}$, 矩阵 A^+ 的行(列)为矩阵 A^* 的行(列)的线性组合。则称矩阵 $A^+ \in \mathbb{C}^{n \times m}$ 为矩阵 $A \in \mathbb{C}^{m \times n}$ 的 **Moore-Penrose 伪逆矩阵** (*псевдообратная матрица Мура-Пенроуза*) 或 **广义逆矩阵** (*обобщённая обратная матрица Мура-Пенроуза*)

引理 1.6. 若矩阵 B 和 C 为矩阵 A 的骨架分解的组成成分, 则矩阵 B^*B 和 CC^* 非退化

证明. 设 x 为方程 $B^*Bx = 0$ 的任意解, 下证其只能为 0。将方程两侧左乘 x^* 即得 $x^*B^*Bx = (Bx)^*Bx = 0$, 亦即 $Bx = 0$ 。但矩阵 B 列满秩, 则 $x = 0$ 为唯一解。由此可得, $\det B^*B \neq 0$ 。 CC^* 的非退化性证明类似 $\square$

定理 1.29. (Moore-Penrose 伪逆矩阵存在唯一性/Moore-Penrose 伪逆矩阵第二构造方式) 任意矩阵 A 的 Moore-Penrose 伪逆矩阵 A^+ 存在且唯一, 并由公式

$$A^+ = C^+B^+ = C^*(CC^*)^{-1}(B^*B)^{-1}B^*$$

表示, 其中 B 和 C 为矩阵 A 的骨架分解的组成成分

证明. 存在性: 若 $A = 0$, 则设 $A^+ = 0$ 。令 $A \neq 0$, 则有骨架分解 $A = BC$ 。根据 Moore-Penrose 伪逆矩阵的定义有

$$BB^+B = B, B^+ = \tilde{U}B^* \Rightarrow B\tilde{U}B^*B = B$$

将等式两侧同时左乘矩阵 B^* 即得 $B^*B\tilde{U}B^*B = B^*B$ 由引理 (1.6) 得 B^*B 的非退化性, 即得 $\tilde{U} = (B^*B)^{-1}$, 则有 $B^+ = (B^*B)^{-1}B^*$, 类似可得公式 $C^+ = C^*(CC^*)^{-1}$

下证矩阵 C^+B^+ 为矩阵 A 的 Moore-Penrose 伪逆矩阵。令 $K = (CC^*)^{-1}(B^*B)^{-1}$, 则有

$$AA^+A = BCC^*(CC^*)^{-1}(B^*B)^{-1}B^*BC = BC = A$$

$$A^+ = C^*KB^* = C^*K(CC^*)^{-1}CC^*B^* = UA^*$$

$$A^+ = C^*KB^* = C^*B^*B(B^*B)^{-1}KB^* = A^*V$$

其中 $U = C^*K(CC^*)^{-1}C, V = B(B^*B)^{-1}KB^*$

唯一性：假设存在两个 Moore-Penrose 伪逆矩阵 A_1^+ 和 A_2^+ ，则有

$$\begin{aligned} AA_1^+A &= AA_2^+A = A, A_1^+ = U_1A^* = A^*V_1, A_2^+ = U_2A^* = A^*V_2 \\ \Rightarrow A(A_1^+ - A_2^+)A &= 0, A_1^+ - A_2^+ = (U_1 - U_2)A^* = A^*(V_1 - V_2) \end{aligned}$$

再令 $D = A_1^+ - A_2^+, U = U_1 - U_2, V = V_1 - V_2$ ，则有

$$\begin{aligned} ADA &= 0, D = UA^* = A^*V \\ \Rightarrow (DA)^*DA &= A^*D^*DA = A^*V^*ADA = 0 \Rightarrow DA = 0 \end{aligned}$$

则得 $DD^* = DAU^* = 0 \Rightarrow D = 0 \Rightarrow A_1^+ = A_2^+$ ，定理即证

□

定理 1.30. (齐次线性方程组通解结构) 齐次线性方程组 $Ax = 0$ 的通解为 $x = (I - A^+A)q$, 其中 q 为维数合适的任意向量

证明. 任意向量 q 满足

$$A((I - A^+A)q) = Aq - AA^+Aq = Aq - Aq = 0$$

对线性方程组的 $Ax = 0$ 的任意解 x , 可假设 $x = q$, 则有

$$(I - A^+A)x = x - A^+Ax = x$$

定理即证 □

注: 该定理表明假设矩阵 A 列满秩, 则 $A^+A = I$. 线性方程组 $Ax = 0$ 的解唯一当且仅当矩阵 A 列满秩. 若线性方程组的解不唯一, 则存在解的无穷集

定理 1.31. (线性方程组解存在充要条件) 设 $A \in \mathbb{C}^{m \times n}, b \in \mathbb{C}^m$, 则下列命题等价

- 1) 方程 $Ax = b$ 有解
- 2) $\text{rank}[A, b] = \text{rank } A$
- 3) $AA^+b = b$

证明. 1) $\Leftrightarrow$ 2): 由 Kronecker-Capelli 定理 (теорема Кронекера-Капелли) 即得

1) $\Leftrightarrow$ 3): 假设线性方程 $Ax = b$ 相容, 即存在 $\tilde{x}$ 满足 $A\tilde{x} = b$, 则有

$$b = A\tilde{x} = AA^+A\tilde{x} = AA^+b$$

即满足 3)

现假设 $AA^+b = b$, 取 $\tilde{x} = A^+b$, 则有 $A\tilde{x} = AA^+b = b$ 定理即证 □

推论 1.32. (线性方程组通解结构) 线性方程组 $Ax = b$ 的通解可表示为 $x = A^+b + (I - A^+A)q$, 其中 q 为任意向量

证明. 由线性方程组解存在充要条件 (1.31) 有 $AA^+b = b$, 令 $x^0 = x - A^+b$, 则有

$$Ax = b \Leftrightarrow Ax = AA^+b \Leftrightarrow A(x - A^+b) = 0 \Leftrightarrow Ax^0 = 0$$

由齐次线性方程组通解结构 (1.30) 即得 $x^0 = (I - AA^+)q$, 即 $x = A^+b + (I - A^+A)q$ □

References